
ANÁLISIS GEOQUÍMICO MULTIVARIADO AUTOMATIZADO UTILIZANDO MACHINE LEARNING PARA LA PROSPECCIÓN DE PÓRFIDOS

A PREPRINT

**Rai Torres¹, Juan Quelal¹, Alexis Cantares¹, Bryan Lascano¹,
Aarón Garrido¹, Christian Mejia-Escobar¹, Jonathan Albuja²**

¹Facultad de Ingeniería en Geología, Minas, Petróleos y Ambiental (FIGEMPA),
Universidad Central del Ecuador, Quito, Ecuador

²Geoligans Consulting S.A.S., Quito, Ecuador

{retorresn, jfquelal, alcantares, bflascano, kagarrido, cimejia}@uce.edu.ec
geoligansconsulting@gmail.com

August 13, 2026

ABSTRACT

El descubrimiento de yacimientos minerales de tipo pórfido de cobre depende críticamente de la identificación de firmas de fertilidad magmática en rocas ígneas de arco. Sin embargo, las metodologías tradicionales basadas en diagramas de discriminación bidimensionales omiten la interacción de múltiples variables y son altamente sensibles a ruidos analíticos o valores faltantes de laboratorio. Este artículo describe de manera exclusiva el procedimiento práctico, secuencial y sistemático ejecutado a nivel de software para preprocesar, etiquetar, clasificar y mapear datos geoquímicos multielementales sin recurrir a formulaciones matemáticas abstractas. En primer lugar, se describe la ingesta e imputación infinitesimal de una base de datos de 38 elementos químicos. Posteriormente, se detalla el entrenamiento de un Autoencoder profundo para la extracción no lineal de características en un espacio latente de cinco dimensiones, sobre el cual se aplicó un algoritmo de Mezcla Gaussiana para aislar anomalías de laboratorio y etiquetar muestras fértiles y estériles. Estas etiquetas sirvieron para entrenar una red neuronal supervisada profunda encargada de predecir la probabilidad de mineralización, cuyas decisiones fueron auditadas mediante el modelo explicativo de atribución de Shapley (SHAP). Finalmente, se expone el proceso de interpolación espacial mediante splines cúbicos y la arquitectura del módulo de atención cruzada de un *Transformer* para redactar de forma autónoma el informe técnico bajo la norma regulatoria internacional canadiense NI 43-101. Este flujo de trabajo reduce drásticamente la incertidumbre analítica y automatiza la toma de decisiones críticas en campañas de exploración minera regional.

Keywords Pórfidos Cupríferos · Fertilidad Magmática · Aprendizaje no Supervisado · Aprendizaje Supervisado · Explicabilidad SHAP · LMM

1 Introducción

A nivel mundial, existe una creciente demanda por elementos críticos como el cobre, impulsada por la transición energética Valenta et al. [2019]. Por ello, la industria de la exploración de recursos minerales se enfrenta a una gran barrera donde los métodos tradicionales ya no son suficientes para descubrir nuevos yacimientos minerales, y el futuro depende precisamente de enfocarse en los depósitos ciegos (*blind targets*) Blain [2000], Joly et al. [2012]. La capacidad de descifrar los patrones asociados a estos depósitos se convierte en una tarea sumamente compleja, extendiendo por años el tiempo necesario para encontrar nuevas oportunidades en condiciones geográficas poco favorables Hronsky and

Groves [2008]. En este contexto, resulta indispensable evolucionar hacia nuevas metodologías que permitan evaluar la fertilidad magmática con mayor precisión y velocidad Harris and Grunsky [2015].

En la práctica, este modelo predictivo se puede aplicar para optimizar drásticamente el capital y el tiempo en las campañas de exploración minera Lord et al. [2001]. Al identificar con precisión las firmas geoquímicas que indican mineralización Chaffee [1982], se permite a las empresas reducir el riesgo financiero y la huella ambiental McNulty and Jowitt [2019], asegurando que las costosas y altamente invasivas perforaciones se dirijan exclusivamente hacia anomalías validadas matemáticamente Gonçalves et al. [2022].

El problema medular radica en la incapacidad de procesar y comprender eficazmente los datasets geoquímicas modernas, las cuales son masivas y multidimensionales Grunsky [2010]. El desafío consiste en que los indicios mineralización profunda quedan ocultos entre decenas de variables y elementos traza, formando patrones no lineales que escapan a la percepción humana Agterberg [2014], Zangeneh et al. [2024].

Tradicionalmente, la industria y la academia han abordado este problema mediante el análisis petrológico clásico, que no ha tenido avances sustanciales en varias décadas, basándose en el uso de diagramas de dispersión bidimensionales o ternarios Rollinson [1993], como los gráficos de Harker Harker [1909], el diagrama AFM Irvine and Baragar [1971] o la relación Sr/Y Vs. Y Defant and Drummond [1990], Richards [2011]. Estos métodos exigen proyectar la química compleja de la roca en planos simples para intentar visualizar empíricamente las tendencias de fraccionamiento magmático.

La principal debilidad identificada en estos métodos tradicionales es su sesgo bidimensional, el cual ignora las interacciones sistémicas al reducir un entorno de alta dimensionalidad a solo dos o tres variables. Esto provoca una pérdida crítica de información y limita la detección de relaciones ocultas entre elementos que no encajan en los modelos visuales estándar, llevando frecuentemente a falsos positivos o a catalogar áreas prospectivas como zonas estériles.

Es así que, esta propuesta nace de la iniciativa de re-evaluar la inmensa cantidad de datos históricos subutilizados, adaptando el uso de Machine Learning. Al reemplazar el análisis cualitativo por un análisis estadístico y computacional, es posible desarrollar nuevas herramientas mas precisas y objetivas.

El objetivo general es desarrollar y validar una herramienta computacional capaz de clasificar la fertilidad de secuencias magmáticas mediante el análisis de datos geoquímicos. Específicamente, se busca comprimir la información multielemental para encontrar patrones, agrupar probabilísticamente las muestras en clusters y automatizar la generación de reportes que traduzcan estos hallazgos en directrices claras para la inversión.

La metodología desarrollada se compone de cinco etapas para la evaluación de la fertilidad magmática a partir de 38 variables geoquímicas con 15175 registros (muestras tomadas en campo). La fase inicial comprende la recolección y preprocesamiento de datos, preparando una tabla estructurada lista para la etapa de aprendizaje no supervisado. En esta segunda fase, se entrena un Autoencoder para la compresión y extracción de características condensadas, seguido de un Modelo de Mezcla Gaussiana (MMG). Ambos algoritmos se someten a rigurosas iteraciones de evaluación y ajuste de hiperparámetros para estructurar finalmente las etiquetas del dataset. Posteriormente, la etapa de aprendizaje supervisado emplea estas etiquetas para entrenar un modelo predictivo de redes neuronales artificiales (RNA), el cual, tras su respectiva optimización, genera predicciones probabilísticas (entre 0 y 1), cuya interpretabilidad se examina mediante análisis SHAP. Finalmente, la arquitectura se completa con la generación de gráficos (mapas geoquímicos y diagramas multivariados) que alimentan la fase culminante de generación de reportes: mediante el uso de ingeniería de prompts y un Modelo de Lenguaje Grande (MLG) para el análisis y la interpretación, el sistema produce de forma autónoma un reporte técnico estructurado bajo el estándar internacional NI 43-101 en una aplicación web de libre acceso.

Como principales aportes de esta investigación se obtuvieron gráficas binarias y ternarias, añadiendo un componente de variabilidad que enriquece el análisis con nuevas relaciones geoquímicas y litogeoquímicas. A través del análisis SHAP, el sistema identifica relaciones clave como Fe vs Cr, V vs Ti y Cu vs K, vinculándolas directamente al valor de fertilidad. Asimismo, la investigación contribuye con la generación automática de reportes de exploración geológica bajo la normativa canadiense NI 43-101, lo que reduce significativamente el tiempo de redacción, disminuye la incertidumbre en la interpretación de datos en diagramas geoquímicos y optimiza los recursos económicos, así como el tiempo necesario para la toma de decisiones en la búsqueda de blancos exploratorios.

El resto de este artículo se estructura de la siguiente manera: la Sección 2 examina el estado del arte, destacando la evolución desde los métodos empíricos bidimensionales hacia las arquitecturas de aprendizaje profundo aplicadas a la exploración mineral. La Sección 3 detalla exhaustivamente el diseño metodológico secuencial, abarcando el preprocesamiento de los datos composicionales, el acoplamiento algorítmico de los modelos no supervisados y supervisados, y la configuración para la generación automatizada de reportes. La Sección 4 expone el entorno experimental y evalúa cuantitativamente el rendimiento y la convergencia de la arquitectura propuesta. En la Sección 5

se discuten las implicaciones petrológicas de los resultados obtenidos, validando las fronteras de decisión del modelo mediante el marco de interpretabilidad frente a los sesgos analíticos tradicionales. Finalmente, las Secciones 6 y 7 sintetizan las conclusiones de la investigación y delinean las directrices metodológicas para futuros trabajos.

2 Estado del Arte

La integración de la inteligencia artificial en la exploración geológica ha dado lugar a una literatura científica reciente (Tabla 1) y en expansión, trazando la evolución desde los análisis bivariados tradicionales hasta la implementación de modelos no supervisados. Tradicionalmente, metodologías lineales como el Análisis de Componentes Principales (PCA) y algoritmos de particionamiento como K-means han dominado el mapeo de anomalías geoquímicas multivariadas (Zuo and Wang [2020]). Sin embargo, estos enfoques fallan al asumir relaciones lineales y homogeneidad estadística en sistemas magmáticos complejos caracterizados por fraccionamiento mineral y halos de alteración (Xiong et al. [2021]). Para superar la desconfianza en modelos de "caja negra", el marco interpretativo SHAP ha aportado transparencia mediante puntuaciones de contribución aditivas (Lundberg and Lee [2017a]), mientras que las arquitecturas generativas tipo Transformer han optimizado la automatización documental (Vaswani et al. [2017]).

La evolución de la investigación en exploración mineral evidencia una transición cronológica clara desde el análisis petrológico clásico hacia el modelamiento con inteligencia artificial. Inicialmente, Loucks [2014] sentó bases fundamentales al demostrar que la fertilidad magmática está ligada a magmas hidratados y oxidados mediante el fraccionamiento temprano. Posteriormente, el enfoque computacional comenzó a consolidarse con Zuo and Wang [2020], el cual logró reducir el sesgo humano en la prospección utilizando algoritmos tradicionales. El salto directo hacia las arquitecturas profundas fue marcado por Xiong et al. [2021], quienes extrajeron características no lineales y demostraron que los espacios latentes retienen eficazmente las anomalías de elementos traza. Al año siguiente, Gonçalves et al. [2022] innovaron en la clasificación de dominios litogeoquímicos modelando fronteras difusas mediante probabilidades continuas. Finalmente, Zangeneh et al. [2024] aportaron una optimización clave en la selección automática de características y la detección espacial de anomalías hidrotermales.

Tabla 1: Resumen sintético del Estado del Arte.

Autor(es)	Nombre del Documento	Datos / Datasets	Modelo / Algoritmo	Aporte del Documento
Loucks [2014]	Distinctive geochemical signatures of barren versus porphyry copper-fertile magmas	Datos geoquímicos globales (Sr/Y , V/Sc).	Diagramas Bivariados, Vectores de Fraccionamiento.	Demostró que la fertilidad magmática está ligada a magmas hidratados y oxidados mediante fraccionamiento temprano.
Zuo and Wang [2020]	Machine learning for mineral prospectivity mapping	Datos geoquímicos multivariados y cartografía geológica.	Random Forest, PCA, K-Means.	Reducen el sesgo humano en el mapeo de prospectividad mineral mediante algoritmos tradicionales de ML.
Xie et al. [2021]	Mapping multivariate geochemical anomalies associated with mineral deposits using autoencoders	Sedimentos de corriente y muestras de roca.	Autoencoders (AE), Redes Profundas (DNN).	Extrajeron características no lineales, demostrando que los espacios latentes retienen anomalías de elementos traza.
Gonçalves et al. [2022]	Lithogeochemical domain classification using Gaussian Mixture Models in porphyry deposits	Datos litogeoquímicos de pozos de perforación.	Gaussian Mixture Models (GMM).	Clasificación de dominios litogeoquímicos modelando fronteras difusas mediante probabilidades continuas.
Zangeneh et al. [2024]	Geochemical anomaly detection and feature selection using Variational Autoencoders (VAEs)	Datos geoquímicos multielementales en pórfidos.	Variational Autoencoders (VAE).	Optimización en la selección automática de características y detección espacial de anomalías hidrotermales.
Lundberg and Lee [2017b]	A Unified Approach to Interpreting Model Predictions	Benchmarks sintéticos y reales (tabulares, genómica e imágenes).	SHAP (SHapley Additive exPlanations: KernelSHAP y DeepSHAP).	Marco de explicabilidad unificado con rigor matemático (consistency, local accuracy) para cuantificar el impacto exacto de cada variable en modelos caja negra.
NI 43-101 Canadian Securities Administrators [2011]	National Instrument 43-101: Standards of Disclosure for Mineral Projects	Estándares normativos y de divulgación minera.	Modelos Transformers / Automatización.	Generación automática de reportes de exploración bajo normativa canadiense, optimizando decisiones estratégicas.

Aunque el aprendizaje profundo ha optimizado la detección de anomalías, persiste la carencia de flujos de trabajo auditables que aislen eficazmente las firmas exclusivas de pórfidos. Para solventarlo, este trabajo propone un marco metodológico de cinco etapas que supera la opacidad algorítmica acoplando Autoencoders, GMM y validación explicativa mediante SHAP. A continuación, se detalla este diseño experimental, desde el tratamiento del efecto de clausura hasta su despliegue en una aplicación web interactiva.

3 Materiales y Métodos

El objetivo central de esta investigación es desarrollar una metodología y un modelo para automatizar y optimizar la clasificación de la fertilidad magmática, para suprimir las limitaciones analíticas de los métodos geoquímicos convencionales.

La estrategia metodológica se fundamenta en un diseño computacional secuencial que integra técnicas de aprendizaje automático y finaliza en un despliegue operativo en la web.

La contribución principal radica en la consolidación de un sistema predictivo auditable que minimiza la incertidumbre humana en la selección de vectores exploratorios. El marco propuesto se ejecuta en cinco grandes pasos (Figura 1).




Figura 1: Diagrama de flujo metodológico, detallando la secuencia del sistema implementado desde la adquisición de datos hasta la generación del reporte NI 43-101.

El diseño metodológico se articula como un flujo de trabajo secuencial donde cada fase prepara el entorno analítico para la siguiente. El proceso inicia con el preprocesamiento estadístico de los datos geoquímicos crudos, aplicando transformaciones logarítmicas y estandarización paramétrica para mitigar el efecto de clausura (Aitchison [1986]). Una vez estabilizado el espacio de datos, se ejecuta una fase de aprendizaje no supervisado que acopla un *Autoencoder* y un Modelo de Mezcla Gaussiana (MMG). Esta arquitectura reduce la dimensionalidad y define las características condensadas, estructurando clases que actúan como variables de entrada directas para la tercera etapa. En esta fase supervisada, una red neuronal profunda (Abadi et al. [2016], Chollet et al. [2015]) genera probabilidades continuas de fertilidad magmática entre 0 y 1. Posteriormente, para evitar la opacidad algorítmica y garantizar la validación petrológica, la cuarta etapa integra el marco matemático SHAP (Lundberg and Lee [2017a]), el cual despliega gráficos de interpretabilidad que auditan el peso predictivo de cada elemento químico. Finalmente, la consolidación de este flujo se materializa en una plataforma web interactiva basada en Streamlit (Streamlit Inc. [2024]). Esta herramienta operativiza el modelo predictivo, permitiendo la ingesta masiva de datos, la inferencia automatizada y la descarga dinámica de los resultados que alimentarán el reporte de exploración.

3.1 Datos

Para la caracterización litogeoquímica y la evaluación del potencial de fertilidad magmática, se estructuró un dataset multielemental georreferenciado (UTM, WGS 84) consolidado a partir de 15 175 muestras de roca total (Tabla 2) procedentes de cartografía geológica de superficie, trincheras y perforación diamantina. El conjunto comprende 38 elementos distribuidos en cuatro categorías fundamentales: elementos mayores (SiO_2 , Al_2O_3 , $Fe_2O_3^T$, CaO , MgO , Na_2O , K_2O , TiO_2 , P_2O_5 , MnO) para la clasificación litológica e índices de alteración Frost et al. [2001], Middlemost [1994]; menores y volátiles (S , C , LOI) sensibles a procesos metasomáticos, donde la pérdida por calcinación (LOI) cuantifica la hidratación e intensidad hidrotermal Santosh and Omori [2010]; elementos traza (Sr , Y , V , Sc , Zr , Nb , Th , U , Ba , Rb , Cu , Cr , Ni , Zn , Pb) para rastrear fraccionamiento y fusión parcial Green [1994], Winchester and Floyd [1977]; y tierras raras ($REEs$: $La-Lu$) para evaluar fases residuales y la fugacidad de oxígeno mediante

anomalías de europio (Eu/Eu^*) Lang and Tittley [2001], Brenan et al. [1995]. Si bien el número de elementos puede adaptarse según la disponibilidad del laboratorio, es imperante contar con Sr , Y , V y Sc para la aplicación efectiva de la metodología. Conforme a la norma ISO/IEC 17025 International Organization for Standardization and International Electrotechnical Commission [2017], la preparación física incluyó el secado a 60°C , trituration ($> 85\%$ a $< 2\text{ mm}$), homogeneización en divisor Jones y pulverización en cazoletas de acero al cromo o carburo de tungsteno ($> 95\%$ a $< 75\ \mu\text{m}$) Esbensen and Wagner [2020]. Los elementos mayores y el LOI se determinaron por fusión con borato de litio seguida de XRF o ICP-OES Reimann et al. [2008], junto con gravimetría por ignición a 1000°C . Por su parte, los elementos traza y $REEs$ se analizaron mediante ICP-MS previa digestión total con cuatro ácidos ($HF - HNO_3 - HClO_4 - HCl$), disolviendo fases refractarias (zircón, titanita, espinelas) y volatilizand el silicio como SiF_4 Totland et al. [1992], Hall [1992]. La calidad e integridad del dataset se garantizó con un programa de QA/QC (12% de muestras de control insertadas ciegamente) Stanley and Lawie [2007], utilizando materiales de referencia certificados para validar la exactitud dentro de ± 2 desviaciones estándar Kane [1992], blancos de cuarzo estéril para descartar contaminación cruzada ($< LDL$) 5% Stanley and Sinclair [1990].

Tabla 2: Muestra de datos estructurados para el entrenamiento (38 características)

Id	MSLINK	NMUESTRA	LONGITUD	LATITUD	ELEVACION	NOMBRE	FECHA	AU	AG	CU	...	SC	TA	TI	ZR	AS	SB	HG	PT	PD	ZONA
0	1	2	719346.12	9896772.68	1799.40	LA MANA	1995-09-25	13.00	0.66	70.0	...	6.00	6.66	0.1400	0.66	2.66	1.26	0.047	0.00	0.00	4
1	2	3	650355.00	9646206.00	1426.82	UZHCURRUMI	1995-09-25	9.00	0.66	14.0	...	6.00	6.66	0.1500	0.66	10.40	1.26	0.044	0.00	0.00	1
2	3	4	700937.38	9839750.67	795.26	S.J. DE CAMARONES	1997-01-10	3.33	0.66	34.5	...	3.33	6.66	0.1500	4.00	8.00	1.26	0.050	0.00	0.00	3
3	4	5	677572.00	9616385.00	1951.60	MANU	1996-05-08	3.33	0.66	5.0	...	3.33	6.66	0.0600	4.00	7.80	1.26	0.026	0.00	0.00	1
4	5	7	654013.00	9647648.00	2215.00	UZHCURRUMI	1995-09-25	3.33	0.66	10.0	...	3.33	6.66	0.0066	0.66	29.70	1.26	0.093	0.00	0.00	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
15170	15171	16992	776678.12	10072712.50	1199.90	RIO LAS PIEDRAS	1999-11-17	3.33	0.66	223.0	...	21.00	6.66	0.2200	7.00	2.66	1.26	0.026	8.00	11.00	5
15171	15172	16993	769023.42	10051706.25	3002.92	APUELA	1999-09-17	40.00	0.66	18.0	...	3.33	6.66	0.1400	0.66	2.66	1.26	0.026	3.33	0.66	5
15172	15173	16994	763096.90	10069756.07	701.19	RIO LAS PIEDRAS	1999-09-30	7.00	0.66	71.0	...	10.00	6.66	0.1500	4.00	2.66	1.26	0.026	3.33	5.00	5
15173	15174	16997	764931.54	10067093.50	914.60	RIO LAS PIEDRAS	1999-09-28	4902.00	0.66	89.0	...	9.00	6.66	0.1500	2.00	10.00	1.26	0.026	682.00	19.00	5
15174	15175	16999	769490.24	10063087.41	1400.13	RIO LAS PIEDRAS	1999-09-25	15.00	0.66	41.0	...	6.00	6.66	0.1000	0.66	2.66	1.26	0.026	3.33	3.00	5

Como paso previo al modelado, se seleccionaron exclusivamente los 38 elementos químicos de interés para evitar el sesgo por *data leakage* y estructurar una matriz analítica limpia de 15 175 muestras por 38 características. Para mitigar las heterogeneidades inherentes al muestreo y los límites de detección instrumental (LDL), los registros numéricos nulos o ceros fueron depurados e imputados mediante una constante infinitesimal ($\varepsilon = 10^{-5}$), lo que previene la distorsión topológica y la indeterminación matemática en fases posteriores Reimann et al. [2008].

Debido a que los datos litogeoquímicos exhiben distribuciones asimétricas y relaciones de falsa correlación por el efecto de clausura composicional Aitchison [1986], se aplicó una transformación logarítmica en base 10:

$$X_{\log} = \log_{10}(X + \varepsilon) \quad (1)$$

Asimismo, para evitar que los elementos mayores dominen la función de pérdida frente a las trazas y las tierras raras, los valores transformados se sometieron a una estandarización paramétrica ($Z\text{-score}$):

$$X_{\text{scaled}} = \frac{X_{\log} - \mu}{\sigma} \quad (2)$$

donde μ representa la media muestral de la variable transformada y σ corresponde a su desviación estándar. Este acondicionamiento centrado en cero garantiza que las redes neuronales procesen de forma equitativa y sin sesgos de escala la firma multivariada global del sistema geológico Goodfellow et al. [2016].

Tabla 3: Dataset de 38 features y 15175 muestras.

Id	AU	AG	CU	PB	ZN	MO	NI	CO	CD	BI	...	NB	SC	TA	TI	ZR	AS	SB	HG	PT	PD
0	13.00	0.66	70.0	11.00	226.0	0.7	23.0	46.0	1.30	4.0	...	4.00	6.00	6.66	0.1400	0.66	2.66	1.26	0.047	0.00001	0.00001
1	9.00	0.66	14.0	22.00	88.0	0.7	7.0	10.0	0.46	4.0	...	3.00	6.00	6.66	0.1500	0.66	10.40	1.26	0.044	0.00001	0.00001
2	3.33	0.66	34.5	12.50	63.0	1.8	15.5	15.0	0.46	4.0	...	0.66	3.33	6.66	0.1500	4.00	8.00	1.26	0.050	0.00001	0.00001
3	3.33	0.66	5.0	14.00	67.0	2.0	4.0	10.0	0.46	4.0	...	0.66	3.33	6.66	0.0600	4.00	7.80	1.26	0.026	0.00001	0.00001
4	3.33	0.66	10.0	51.00	139.0	0.7	4.0	4.0	1.10	4.0	...	3.00	3.33	6.66	0.0066	0.66	29.70	1.26	0.093	0.00001	0.00001
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
15170	3.33	0.66	223.0	2.66	99.0	0.7	40.0	36.0	0.46	4.0	...	13.00	21.00	6.66	0.2200	7.00	2.66	1.26	0.026	8.00000	11.00000
15171	40.00	0.66	18.0	2.66	56.0	0.7	10.0	9.0	0.46	4.0	...	10.00	3.33	6.66	0.1400	0.66	2.66	1.26	0.026	3.33000	0.66000
15172	7.00	0.66	71.0	6.00	82.0	1.0	24.0	24.0	0.46	4.0	...	12.00	10.00	6.66	0.1500	4.00	2.66	1.26	0.026	3.33000	5.00000
15173	4902.00	0.66	89.0	2.66	82.0	2.0	33.0	30.0	0.46	4.0	...	37.00	9.00	6.66	0.1500	2.00	10.00	1.26	0.026	682.00000	19.00000
15174	15.00	0.66	41.0	2.66	59.0	1.0	11.0	13.0	0.46	4.0	...	9.00	6.00	6.66	0.1000	0.66	2.66	1.26	0.026	3.33000	3.00000

4 Experimentación

4.1 Aprendizaje No Supervisado

El aprendizaje no supervisado se desarrolló en dos etapas integradas: la compresión geométrica de los datos geoquímicos y su subsecuente clasificación probabilística. Para aislar las señales más importantes de los datos, se diseñó una red neuronal tipo *Autoencoder* simétrica (Xiong et al. [2021]). El codificador comprimió la información estandarizada a través de dos capas ocultas (de 16 y 8 neuronas, con activación ReLU) hasta alcanzar un espacio latente de apenas cinco dimensiones, ya que si se tuviese más de cinco dimensiones, se perdería el efecto cuello de botella, donde autoencoder se vería forzado a aprender una representación comprimida y abstracta de los datos, generando un efecto de memorización; asimismo no se generan menos de cinco dimensiones para preservar la varianza y vínculos geoquímicos, evitando underfitting, perdiendo la capacidad de reconstruir la varianza total de datos, esta mejora se refleja en la curva de pérdida, esta arquitectura se observa en la figura 2. Esta compresión forzó al modelo a aprender y retener únicamente las varianzas geoquímicas fundamentales, filtrando el ruido de fondo. El decodificador reconstruyó la señal original a través de capas espejo. La red se optimizó durante 50 épocas utilizando el algoritmo Adam, reservando un 20% de las muestras para auditar la función de pérdida y asegurar la capacidad de generalización del modelo. Además se ajustaron parámetros e hiperparámetros, resumidos en la Tabla 4.




Figura 2: Arquitectura de autoencoder.

Tabla 4: **Hiperparámetros y Arquitectura del Autoencoder (Extracción de Características Latentes)**

Hiperparámetro / Parámetro	Configuración / Valor
Dimensión de Entrada (D_{in})	38 variables (Elementos litogeoquímicos en $\log_{10}$)
Transformación Previa	Escalado Estándar (Z-score)
Estructura del Codificador (Encoder)	Input (38) $\rightarrow$ Dense(16, ReLU) $\rightarrow$ Dense(8, ReLU) $\rightarrow$ Dense(5, Linear)
Estructura del Decodificador (Decoder)	Dense(8, ReLU) $\rightarrow$ Dense(16, ReLU) $\rightarrow$ Output (5, Linear)
Dimensión del Espacio Latente	5 componentes
Función de Activación Ocultas	ReLU (<i>Rectified Linear Unit</i>)
Función de Activación Salida	Lineal
Optimizador	Adam
Función de Pérdida (Loss)	Error Cuadrático Medio (<i>Mean Squared Error</i> - MSE)
Épocas de Entrenamiento (<i>Epochs</i>)	50
Tamaño de Lote (<i>Batch Size</i>)	64
División de Validación (<i>Validation Split</i>)	20%

Para evaluar la estabilidad del entrenamiento y descartar un posible sobreajuste (overfitting) o underfitting, se examinó la evolución temporal de las métricas de entrenamiento y validación, a lo largo de las 50 épocas de optimización. La convergencia progresiva de la curva de entrenamiento (train en azul) y la curva de validación (validation en naranja) permite auditar cuantitativamente la capacidad de reconstrucción del Autoencoder, como se muestra en la figura 3.




Figura 3: Métrica de entrenamiento y validación de autoencoder.

Una vez estabilizada la arquitectura, se extrajeron las características de este espacio latente de cinco dimensiones. Esta topología reducida demostró ser el equilibrio ideal, ya que logró retener la mayor cantidad de información geoquímica útil manteniendo un error de reconstrucción mínimo. Sobre este entorno denso y representativo, se aplicó un Modelo de Mezcla Gaussiana (MMG) para parametrizar las clases litológicas (Gonçalves et al. [2022]). A diferencia de los algoritmos que imponen fronteras rígidas, el MMG ofrece un agrupamiento flexible (*soft clustering*). Se configuró con tres componentes y matrices de covarianza completas, otorgando a cada grupo la libertad de adoptar formas elípticas oblicuas que se adaptan naturalmente a la dispersión real de las firmas geoquímicas. La selección de tres clústeres fue respaldada por la minimización del Criterio de Información Bayesiano (BIC), garantizando una partición que es matemáticamente eficiente y lógicamente coherente con los dominios del set de datos: magma fértil, estéril y ruido estadístico, como se muestra en la figura 4. La construcción y ajuste de parámetros e hiperparámetros se resume en la Tabla 5.

Tabla 5: Hiperparámetros del Modelo de Mezclas Gaussianas (GMM - Clustering)

Hiperparámetro / Parámetro	Configuración / Valor
Espacio de Entrada	Espacio latente del Autoencoder (5 dimensiones)
Número de Componentes ($n_{components}$)	3 clústeres (<i>Fértil</i> , <i>Estéril</i> , <i>Artefacto</i>)
Tipo de Covarianza ($covariance_type$)	<i>Full</i> (matriz de covarianza completa por componente)
Semilla Aleatoria ($random_state$)	42
Método de Asignación	Probabilístico (<i>predict_proba</i>)
Etiquetado Petrológico	Basado en promedios de la razón Sr/Y

Este enfoque probabilístico es metodológicamente indispensable porque los procesos petrogenéticos, como la cristalización fraccionada y la asimilación, operan mediante gradientes composicionales continuos y no a través de saltos discretos. La validación geológica de estos clústeres matemáticos se ancló empíricamente en la razón Sr/Y . Al promediar este indicador, la agrupación con el valor máximo de Sr/Y se catalogó como magma "Fértil", reflejando las condiciones de alta presión. De manera crucial, el clúster con el valor ínfimo sirvió para identificar y aislar un "Artefacto" derivado de datos faltantes, depurando el espacio de decisión, mientras que el clúster restante constituyó el dominio "Estéril". Finalmente, el modelo calculó la probabilidad exacta de pertenencia a la clase fértil para cada muestra. Estas métricas continuas permitieron cuantificar la incertidumbre en las fronteras litológicas y mapear visualmente la




Figura 4: Arquitectura GMM.

transición del magma en diagramas bivariados (V/Sc frente a Sr/Y) y proyecciones del espacio latente (PCA), según se observa en la figura 5.




Figura 5: Clusters petrológicos.

4.2 Etiquetado de Datos

Más allá de la extracción automática de patrones en el espacio latente, resultaba indispensable anclar el modelo a la realidad petrogenética. Por ello, se integró una etapa de ingeniería de características clásicas enfocada en construir variables predictivas con un significado geológico irrefutable. Específicamente, se calcularon las razones de elementos traza Sr/Y y V/Sc , métricas fundamentales para evaluar la fertilidad magmática asociada a sistemas porfídicos Loucks [2014]. La razón Sr/Y actúa como un termobarómetro composicional que refleja condiciones de alta presión y engrosamiento cortical (Defant and Drummond [1990]). Físicamente, un cociente elevado evidencia magmas fuertemente hidratados donde la cristalización de la plagioclasa se suprime, reteniendo el estroncio en la fase fundida

(Richards [2011]). De manera simultánea, estas altas presiones fuerzan el fraccionamiento profundo de minerales como el anfíbol o el granate, secuestrando el itrio de la mezcla Loucks [2014].

Por su parte, el cociente V/Sc se utilizó para rastrear el estado de oxidación del sistema. Dado que el vanadio es sumamente sensible al potencial redox durante la cristalización de óxidos, mientras que el comportamiento del escandio permanece inalterable, la relación entre ambos aísla con precisión la firma geoquímica de los magmas oxidados Cooke et al. [2005]. Esta condición oxidante es el motor de la fertilidad magmática, ya que previene la saturación temprana de sulfuros y permite que los metales asciendan disueltos hacia niveles corticales someros Sun et al. [2015], Loucks [2014]. En conjunto, la integración de ambos índices proporciona el marco empírico necesario para auditar geológicamente las fronteras de decisión trazadas por el modelo de aprendizaje no supervisado.

4.2.1 Relevancia Petrológica de Elementos en Características Condensadas

El análisis de sensibilidad sobre la primera capa oculta del Autoencoder revela qué variables ejercen el mayor impacto durante la compresión no lineal de la matriz de datos ($15, 175 \times 38$). Tal como se observa en la contribución ponderada de los pesos, el modelo prioriza analitos asociados a procesos de evolución magmática profunda, metasomatismo e hidatogénesis de metales nobles y base. En la Tabla 6 se detallan los elementos de mayor peso en la reconstrucción del espacio latente y su correspondiente significado petrológico.

Tabla 6: Elementos químicos con mayor peso en el Autoencoder y su significado en la evaluación de la fertilidad magmática.

Elemento	Peso Absoluto ($\sum w_i $)	Importancia Petrológica y Control Magmático-Hidrotermal
Sr	5.73	Sensible a la supresión de plagioclasa y alta presión de agua (H_2O); indicador primario de hidratación y fertilidad magmática.
Pt	5.241	Metal del grupo del platino (PGE); rastrea la saturación temprana de sulfuros en la fuente y la diferenciación del manto.
Pd	4.770	Altamente móvil en fluidos magmático-hidrotermales; indicador clave en la detección de fases sulfuradas precoces.
Zr	3.121	Elemento inmóvil $HFSE$; resistente a la alteración, actúa como trazador litológico y monitorea el fraccionamiento de zircones.
Na	2.996	Componente mayor constitutivo; clave en la diferenciación alcalina y la evaluación de alteración sódica (<i>albitización</i>).
Nb	2.985	Trazador $HFSE$; sensible a las firmas de subducción, espesor cortical y grado de fusión parcial en el manto.
Sn	2.666	Elemento incompatible; útil en el seguimiento de magmas altamente evolucionados y granitos altamente diferenciados.
Te	2.553	Metaloide volátil; trazador de sistemas hidrotermales epitermales/porfiríticos y precipitación de telururos de oro.
K	2.488	Elemento litófilo alcalino; indicador fundamental de metasomatismo potásico (alteración potásica en pórfidos).
Ag	2.441	Metal noble traza; asociado a la movilización de fluidos mineralizadores en halos de alteración distal e intermedia.
Fe	2.395	Elemento mayor redox-sensible; controla la precipitación de óxidos ($Fe-Ti$) y el estado de oxidación del magma.
V	2.311	Sensible al estado de oxidación (fO_2); reemplaza al Fe e Ti en magnetitas en condiciones moderadamente oxidadas.
Sb	2.264	Elemento volátil trazador de halos de alteración superficiales y remoción hidrotermal en sistemas estilo pórfido.
Au	2.231	Elemento de interés económico directo; su integración en el espacio latente permite mapear núcleos de alteración/mineralización.
Ba	2.224	Trazador alcalino-terreo; sustituye al K en feldespatos y mica blanca, registrando eventos de alteración filica/argílica.

4.3 Aprendizaje Supervisado

Una vez estructurado el dataset etiquetado, se abordó la fase supervisada para construir un modelo predictivo capaz de inferir la fertilidad magmática en nuevas muestras y cuantificar la contribución de los elementos químicos. Para

capitalizar las etiquetas generadas durante la fase probabilística y escalar el análisis hacia la explicabilidad de las predicciones, la metodología transitó hacia una etapa de aprendizaje supervisado. El objetivo fundamental consistió en entrenar una Red Neuronal Profunda (DNN) capaz de predecir la fertilidad de las muestras basándose exclusivamente en sus firmas geoquímicas. Inicialmente, los dominios litológicos derivados del Modelo de Mezcla Gaussiana se binarizaron, codificando matemáticamente a los magmas "Fértiles" con un valor de 1, mientras que las categorías de "Estériles" y "Artefactos" se agruparon bajo la clase 0. Para garantizar una evaluación rigurosa y evitar la filtración de información durante el entrenamiento (*data leakage*), el conjunto de datos se dividió, reservando un 20% estrictamente para pruebas ciegas. El escalado de las variables predictoras (estandarización) se aplicó de manera independiente sobre estas particiones, lo que aseguró que el modelo no memorizara estadísticos globales y, simultáneamente, permitió conservar los datos crudos para la subsecuente auditoría de explicabilidad.

La arquitectura de la red predictiva se estructuró para procesar la dimensionalidad geoquímica a través de tres capas ocultas secuenciales de 20, 10 y 5 neuronas, respectivamente (Figura 6). El uso de funciones de activación no lineal ReLU en esta etapa permitió al modelo modelar las complejas interacciones termodinámicas entre los elementos traza. La capa de salida constó de una única neurona con activación sigmoidea, diseñada para transformar la señal final en una probabilidad de pertenencia continua entre 0 y 1. La red se optimizó mediante el algoritmo Adam, minimizando la función de pérdida de entropía cruzada binaria (*binary crossentropy*) durante 50 épocas y procesando lotes de 64 muestras. Para asegurar la generalización del modelo, un 20% de la data de entrenamiento se aisló como segmento de validación interna. El ajuste de hiperparámetros se detalla en la Tabla 7.

Finalmente, la robustez predictiva del clasificador se auditó mediante un análisis de rendimiento multidimensional (Figura 9).




Figura 6: Arquitectura del modelo supervisado.

La figura 6 muestra cómo a partir de 5 elementos (características) de entrada y 3 capas ocultas, se llega a la salida, que refleja un valor de probabilidad de fertilidad para cada muestra, etiquetando a posterior el dataset como fértil o estéril.

Para evaluar la dinámica de aprendizaje del clasificador y descartar sesgos de sobreajuste (*overfitting*), se analizó el comportamiento de la red a lo largo de las 50 épocas de optimización. La convergencia paralela entre la precisión (*accuracy*) y la pérdida (*binary crossentropy*) de los conjuntos de entrenamiento y validación permite auditar el proceso de generalización del modelo. A continuación, se examinan las curvas de rendimiento obtenidas durante la fase supervisada, como se observa en la figura 7.

Con el propósito de evaluar la capacidad discriminativa del modelo entrenado ante datos no observados, se realizaron predicciones sobre el conjunto de prueba ciego (20% del dataset original) utilizando un umbral probabilístico de decisión de 0.5. La matriz de confusión resultante permite cuantificar el desempeño del clasificador en términos de verdaderos positivos (muestras fértiles identificadas correctamente) y errores de clasificación (falsos positivos y falsos negativos), sirviendo como base para el análisis detallado de las métricas de evaluación, donde se obtuvieron 1349 muestras fértiles confirmadas, como se observa en la figura 8.

Tabla 7: Hiperparámetros de la Red Neuronal Clasificadora Supervisada

Hiperparámetro / Parámetro	Configuración / Valor
Dimensión de Entrada (D_{in})	38 elementos litogeoquímicos ($\log_{10} + Z$ -score)
Variable Objetivo ($Target$)	Clasificación Binaria (1 = Fértil, 0 = Estéril/Artefacto)
Arquitectura de Capas	Dense(20, ReLU) $\rightarrow$ Dense(10, ReLU) $\rightarrow$ Dense(5, ReLU) $\rightarrow$ Dense(1, Sigmoid)
Capa de Entrada	5 neuronas (con $input_shape=38$)
Capas Ocultas	20-10 y 5 neuronas con activación ReLU
Capa de Salida	1 neurona con activación Sigmoide
Optimizador	Adam
Función de Pérdida (Loss)	Entropía Cruzada Binaria (<i>Binary Crossentropy</i>)
Métrica de Evaluación	Precisión (<i>Accuracy</i>)
Épocas de Entrenamiento (<i>Epochs</i>)	50
Tamaño de Lote (<i>Batch Size</i>)	64
División Entrenar / Prueba (<i>Train/Test</i>)	80% / 20% ($random_state = 42$)
División de Validación Interna	20% sobre el conjunto de entrenamiento
Umbral de Decisión Probabilístico	0.5




Figura 7: Métricas de aprendizaje supervisado. A) Curva de precisión (Accuracy) y B) Curva de pérdida (Binary Crossentropy).




Figura 8: Matriz de confusión.

4.4 Validación Petroológica Mediante SHAP

Para eliminar la opacidad matemática de la red neuronal y dotar de interpretabilidad termodinámica a las predicciones, se implementó un marco de explicabilidad basado en los Valores de Shapley (SHAP, *Shapley Additive exPlanations*) Lundberg and Lee [2017a]. En la teoría de juegos cooperativos, el valor de Shapley, denotado como ϕ_i , calcula la contribución marginal promedio de una característica i en todas las permutaciones posibles del espacio de variables predictoras. Metodológicamente, el algoritmo requirió la definición inicial de un conjunto de datos de referencia (*background dataset*), compuesto por cien muestras aleatorias extraídas del dominio de entrenamiento. Esta línea base es estadísticamente indispensable, ya que establece el valor predictivo esperado (la probabilidad media de observar un magma fértil) antes de introducir cualquier evidencia geoquímica al modelo.

La auditoría de las predicciones se ejecutó mediante un explicador profundo (*DeepExplainer*), un algoritmo optimizado que propaga linealmente las activaciones a través de las capas ocultas de la red para aproximar las contribuciones exactas sobre el conjunto de pruebas. El resultado es la descomposición matemática de cada probabilidad de pertenencia en una suma de los efectos individuales de los elementos químicos. Un valor SHAP positivo indica que la concentración específica de un elemento desvía la predicción por encima de la línea base, empujando la clasificación hacia el dominio "Fértil" asociado a los sistemas porfídicos. Por el contrario, un valor negativo arrastra la probabilidad predictiva hacia las litologías estériles o hacia el umbral de ruido estadístico.

La dinámica multivariada del sistema se evaluó a través de dos enfoques visuales. A nivel macro, el diagrama de resumen (*summary plot*) proyectó simultáneamente la magnitud del impacto de cada elemento y su direccionalidad, permitiendo identificar rápidamente cuáles firmas geoquímicas —y si se asocian a altas o bajas concentraciones— dictan las fronteras litoquímicas del modelo. A nivel micro, la no linealidad petrogenética se capturó mediante diagramas de dependencia parcial (*dependence plot*). Estos gráficos aislaron el elemento de mayor peso predictivo para rastrear cómo fluctúa su valor SHAP a lo largo de su gradiente de concentración natural. Al superponer el mapeo de color de una segunda variable dependiente, este análisis permitió cuantificar la interacción cruzada entre elementos emparejados, revelando acoplamientos geoquímicos análogos a la co-cristalización de ensamblajes minerales en el fundido subvolcánico.

Este análisis permitió descomponer el impacto individual y sinérgico de elementos traza y mayores (Fe , Cr , V , Ti , Cu , K), revelando las fronteras de decisión no lineales que controlan la fertilidad del sistema. Esto se detalla claramente en la figura 9, donde la metodología SHAP genera valores de impacto de fertilidad en el eje X y en el eje Y el grado de importancia del elemento.

5 Resultados

5.1 Generación de Gráficos Multivariados y Mapas Geoquímicos

Los resultados derivados de las fases no supervisada y supervisada se integraron geométricamente para actualizar la representación gráfica tradicional. En lugar de diagramas estáticos planos, el sistema generó automáticamente:




Figura 9: Ponderación multielemental SHAP.

1. **Diagramas Bivariados y Ternarios Enriquecidos:** Gráficos de dispersión (Fe vs. Cr , V vs. Ti , Cu vs. K), diagrama adakítico (Sr/Y vs Y), diagrama Spider, codificados por color según el valor de probabilidad de fertilidad calculada por el modelo, permitiendo observar variaciones composicionales sin perder la multidimensionalidad, como se muestra en la figura 10.




Figura 10: Compendio de gráficas geoquímicas de fertilidad. A) gráfico adakítico Sr/Y vs Y ; B) diagrama Spider y sus curvas de fertilidad; C) diagrama ternario para alteración hidrotermal; D) diagrama Fe vs Cr para fraccionamiento de sulfuro magmático e hidrotermal; E) diagrama Cu vs K para núcleos de alteración potásica y cobre; F) diagrama V vs Ti para estado de oxidación del magma.

2. **Mapas Geoquímicos Espaciales:** Proyección cartográfica vectorial de las 15,175 muestras en coordenadas UTM (WGS84), donde la respuesta probabilística de la red neuronal y los dominios del GMM se interpolan para delimitar geográficamente los blancos de exploración (*blind targets*) de mayor interés, como se muestra en la figura 11.

5.2 Aplicación Web

Para facilitar el acceso a los modelos predictivos de aprendizaje automático aplicados a la fertilidad magmática y permitir su uso en la exploración mineral, se desarrolló una aplicación web interactiva mediante el framework Streamlit bajo una arquitectura de integración continua alojada en GitHub. Esta plataforma traduce algoritmos de evaluación geocientífica basados en Python a una interfaz gráfica accesible, permitiendo al usuario final ejecutar inferencias en tiempo real sin requerir de configuraciones de software locales. El sistema centraliza los modelos pre-entrenados y se encuentra optimizado mediante directivas de caché para minimizar la latencia computacional y el consumo de recursos del servidor, consolidándose como un puente de transferencia tecnológica que garantiza la reproducibilidad metodológica y la aplicabilidad directa de la investigación en el análisis petrológico.

La integración de los resultados algorítmicos se operativiza a través de una aplicación web respaldada por el modelo de lenguaje de gran escala Llama 3.3 (70B Versatile), desplegado sobre infraestructura de inferencia acelerada (LPUs




Figura 11: Mapa de fertilidad.

de Groq). Para evitar el desvanecimiento de gradiente típico de las redes recurrentes en secuencias extensas, este motor opera bajo una arquitectura *Transformer*. El modelo prescinde del procesamiento secuencial mediante el uso de mecanismos de auto-atención escalada (*Scaled Dot-Product Attention*) y codificaciones posicionales. A través de capas de atención de múltiples cabezas y redes de alimentación directa con activaciones no lineales (SwiGLU), la arquitectura proyecta los datos geoquímicos en un espacio vectorial de alta dimensionalidad. Esta capacidad de procesamiento paralelo es matemáticamente indispensable para vincular de forma precisa métricas complejas, como los valores de explicabilidad SHAP y los dominios estocásticos del MMG, con el marco conceptual de la petrología de sistemas porfídicos.

A nivel de interfaz de usuario, este acoplamiento computacional se estructura en un flujo de trabajo continuo y auditable. El entorno web facilita la ingesta inicial del conjunto de datos geoquímicos, presentando de manera inmediata un resumen estadístico y la renderización de las proyecciones gráficas multivariadas generadas por los modelos de aprendizaje automático. Esta visualización integral permite al investigador auditar la calidad y distribución del espacio latente antes de proceder con la generación de inferencias.

El núcleo de valor de la plataforma reside en la síntesis y redacción automatizada de la prospectividad geológica. Aprovechando sus matrices de peso de atención, el modelo lingüístico asocia dinámicamente los elementos críticos identificados por SHAP con procesos magmático-hidrotermales específicos, tales como el estado de oxidación y el fraccionamiento de ensamblajes minerales. Al integrar la salida de la red predictiva profunda y la partición geométrica del MMG, el sistema sintetiza la coherencia espacial de las anomalías para delimitar dominios de alta favorabilidad para la localización de cuerpos ciegos. Finalmente, las relaciones no lineales descubiertas se traducen en prosa técnica formal, generando automáticamente un reporte estructurado bajo los lineamientos de la normativa canadiense NI 43-101. Este documento final formaliza la interpretación petrogenética, cuantifica la incertidumbre estadística y ofrece recomendaciones de perforación estratégicas, reduciendo drásticamente los tiempos de procesamiento de gabinete.

La fase final del entorno computacional automatiza la traducción de los hallazgos numéricos y gráficos en un documento técnico de valor estratégico para la toma de decisiones e inversión.

5.3 Ingeniería de Prompts y Estructuración de Contexto

Se diseñó un flujo de ingeniería de *prompts* avanzado (*Context-Aware Prompting*) que compila metódicamente los *outputs* cuantitativos del sistema: métricas de precisión del modelo, tablas de importancia de variables SHAP, estadísticas descriptivas de los clústeres del GMM y rutas de archivo de las figuras multivariadas. Estos datos se estructuran en formato JSON/Markdown y se enriquecen con instrucciones del estándar canadiense NI 43-101 (*Standards of Disclosure for Mineral Projects*).

5.4 Análisis, Interpretación y Redacción mediante LLM de Alta Velocidad (Groq & Llama 3.3)

El contexto multivariado estructurado alimenta al modelo de lenguaje de gran escala Llama 3.3 (70B Versatile), ejecutado sobre la infraestructura de inferencia acelerada por hardware LPUs (*Language Processing Units*) de Groq. El modelo está fundamentado en la arquitectura *Transformer* Vaswani et al. [2017] y optimizado para el procesamiento y razonamiento de secuencias complejas con una baja latencia de generación. A diferencia de los modelos recurrentes tradicionales (*RNN/LSTM*), los cuales procesan la información de manera secuencial sufriendo desvanecimiento de gradiente en contextos extensos, la arquitectura *Transformer* prescinde del paso temporal continuo en favor de mecanismos de auto-atención escalada (*Scaled Dot-Product Attention*). Matemáticamente, la operación de atención sobre el prompt geoquímico se expresa como:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3)$$

donde Q (*Queries*), K (*Keys*) y V (*Values*) corresponden a las proyecciones lineales del vector de entrada proyectado en un espacio vectorial de alta dimensionalidad, y d_k es el factor de escalamiento que previene la saturación del gradiente en la función *softmax*. Para preservar la coherencia y secuencia de las métricas numéricas y directivas del estándar NI 43-101 dentro del espacio vectorial, el *Transformer* incorpora codificaciones posicionales (*Positional Encodings*) añadidas directamente a los *embeddings* de entrada.

Para capturar simultáneamente múltiples relaciones complejas entre los atributos cuantitativos, Llama 3.3 emplea una capa de atención de múltiples cabezas (*Multi-Head Attention*). Esto permite proyectar las consultas, claves y valores en h subespacios de representación distintos.

Posteriormente, las representaciones procesadas por las cabezas de atención atraviesan redes de alimentación directa capa por capa (*Position-wise Feed-Forward Networks, FFN*), aplicando transformaciones lineales y funciones de activación no lineales (como SwiGLU).

Esta capacidad de procesamiento paralelo y mapeo de dependencias de largo alcance permite al modelo desacoplado en la API de Groq vincular de forma precisa los atributos numéricos de entrada (tales como patrones de *REEs*, valores de explicabilidad SHAP para *Fe* vs. *Cr*, y los dominios estocásticos del GMM) con el marco conceptual de la geología económica y la petrología de sistemas porfiríticos.

Operando como un motor de inferencia avanzada y síntesis técnica, el modelo ejecuta las siguientes funciones automáticas:

- **Interpretación Petrológica Asistida por Atención:** A través de las matrices de peso de atención, el *Transformer* evalúa de manera prioritaria los elementos químicos críticos identificados por SHAP, asociándolos dinámicamente con procesos magmático-hidrotermales específicos (ej. estado de oxidación fO_2 , grado de hidratación del magma, fraccionamiento de anfíbol/plagioclasa y eventos de metasomatismo).
- **Evaluación de Prospectividad y Síntesis de Incertidumbre:** Integrando la salida del perceptrón multicapa y la segmentación del GMM, el modelo sintetiza la coherencia espacial de las anomalías geoquímicas. Identifica los dominios de alta favorabilidad para la localización de cuerpos mineralizados ciegos (*blind targets*) y delimita de forma explícita las zonas de incertidumbre estadística o vacíos de muestreo.
- **Redacción Estandarizada bajo Normativa NI 43-101:** Traduce las relaciones no lineales descubiertas por los modelos no supervisado y supervisado en prosa técnica formal. El sistema construye automáticamente los capítulos clave requeridos por el estándar canadiense (Muestreo, Preparación de Datos, Interpretación Geoquímica, Delimitación de Anomalías y Recomendaciones de Perforación). Este proceso genera un reporte técnico-científico auditable, reduce significativamente los tiempos de elaboración y optimiza la toma de decisiones estratégicas en la exploración minera.

La Tabla 8 resume la arquitectura del LMM de Llama 3.3, mientras que la figura 12 ilustra la arquitectura de *Transformer* utilizada para el desarrollo de la presente investigación.

5.5 Plataforma Computacional y Entorno de Ejecución

El procesamiento matricial y la optimización de los modelos tensoriales se ejecutaron en una arquitectura de cómputo distribuido. En la Tabla 9 se resumen las especificaciones de hardware, el núcleo del sistema operativo y las bibliotecas de cómputo científico empleadas en el desarrollo de la aplicación; además, la figura 13 refleja la interfaz con el usuario y el resultado de la aplicación web desarrollada.

Tabla 8: Parámetros y arquitectura del modelo Llama 3.3 (70B) para la generación de reportes geoquímicos.

Etapas	Componente	Dimensión / Configuración	Función
1	Tokens de entrada	Vocabulario de 128 256 tokens	Convierte texto en tokens procesables por el modelo.
2	Embedding	8192 dimensiones	Transforma cada token en un vector denso de representación semántica.
3	Bloques Transformer	80 bloques	Núcleo de procesamiento y razonamiento del modelo.
3.1	RMSNorm	$\varepsilon = 10^{-5}$	Normaliza las activaciones antes de cada subcapa.
3.2	Self-Attention (GQA)	64 cabezas Q, 8 cabezas KV	Captura relaciones entre tokens y mejora la eficiencia mediante Grouped Query Attention.
3.3	RoPE	Base = 500 000	Codifica información posicional para manejar secuencias largas.
3.4	RMSNorm	$\varepsilon = 10^{-5}$	Normalización previa a la red Feed Forward.
3.5	Feed Forward (SwiGLU)	28 672 neuronas	Incrementa la capacidad de representación y razonamiento.
4	Normalización final	RMSNorm	Estabiliza la salida de los bloques Transformer.
5	Proyección de salida	8192 $\rightarrow$ 128 256	Calcula la probabilidad del siguiente token.
6	Predicción	Token siguiente	Genera la respuesta de manera autorregresiva.




Figura 12: Arquitectura Transformer.

Tabla 9: Especificaciones del entorno computacional, librerías y módulos de software.

Componente / Librería	Especificación Técnica y Rol en el Sistema
Entorno de Ejecución	Google Colab Environment (Linux Kernel, Python 3.10+)
Arquitectura de Hardware	Intel(R) Xeon(R) CPU @ 2.20GHz / Acelerador de Tensores NVIDIA T4 GPU
TensorFlow / Keras	Construcción, compilación y entrenamiento del <i>Autoencoder</i> y el perceptrón multicapa.
Scikit-Learn	Estandarización de variables (StandardScaler), modelos de mezclas gaussianas (GaussianMixture) y métricas de evaluación.
SHAP	Estimación de valores de Shapley mediante la implementación DeepExplainer para atribución no lineal.
Pandas / NumPy	Operaciones matriciales, transformaciones composicionales y álgebra lineal denso.
SciPy / Streamlit	Interpolación de mallas discontinuas mediante la función <i>griddata</i> y despliegue del entorno gráfico en tiempo real.




Figura 13: Aplicación Web. A) Interfaz de la aplicación web, resumen analítico de campaña; B) Tabla de inferencia multivariada; C) Diagramas multivariados y de probabilidad de fertilidad; D) Mapa de fertilidad magmática y E) Generación automática de redacción de informe técnico bajo el estándar canadiense NI 43-101.

6 Conclusiones

La integración de arquitecturas de aprendizaje profundo no supervisado (Autoencoder), clasificadores supervisados y modelos de explicabilidad (SHAP) constituye una alternativa cuantitativa robusta frente a los métodos geoquímicos tradicionales. Este enfoque supera las limitaciones de los diagramas bivariados y lineales (PCA, K-means), permitiendo automatizar la clasificación de fertilidad magmática y garantizar transparencia analítica en informes técnicos bajo la normativa NI 43-101, optimizando tiempos y asegurando rigor científico.

Esto se logró mediante el diseño de la red neuronal Autoencoder en Python que comprime la firma geoquímica completa a través de un cuello de botella latente, su acoplamiento directo con Modelos de Mezcla Gaussiana (GMM) para asignar probabilidades continuas y modelar transiciones geológicas difusas, la integración del marco de interpretabilidad SHAP basado en teoría de juegos para desmitificar los modelos de caja negra, y la incorporación de un flujo automatizado para la generación del informe mediante un lenguaje natural (Llama 3.3).

La reducción dimensional ($38 \rightarrow 5$ variables) demostró que la varianza principal de la matriz geoquímica no depende únicamente de la diferenciación silicatada primaria, sino también de procesos como hidratación magmática profunda, estado de oxidación (fO_2) y metasomatismo hidrotermal. La red neuronal priorizó elementos críticos (Sr , Pt , Pd , Zr , K , Fe , V), confirmando su relevancia en la petrogénesis de sistemas porfíricos.

Por otra parte, el uso de Gaussian Mixture Models permitió particionar estocásticamente el espacio latente y aislar automáticamente un dominio de artefactos (datos nulos). Esto evitó sesgos derivados de truncamientos o imputaciones en valores bajo el límite de detección, mejorando la clasificación de fertilidad frente a los métodos tradicionales.

Además, los valores SHAP revelaron que la probabilidad de fertilidad está guiada por covarianzas multivariadas no lineales, más allá de índices clásicos como Sr/Y y V/Sc Loucks [2014], Richards [2011]. Por ende, se identificaron interacciones clave:

- **Asociación Redox y Fraccionamiento ($Fe-Cr$ y $V-Ti$):** El comportamiento coordinado de Fe , V y Ti refleja el grado de diferenciación y las condiciones de fugacidad de oxígeno (fO_2) durante el enfriamiento del magma. La capacidad del modelo para ponderar V en función de Ti permite discriminar magmas verdaderamente oxidados de aquellos con empobrecimiento secundario por alteración.
- **Firma Hidrotermal y Metasomatismo ($Cu-K$):** La relación entre K y Cu es un trazador directo de la transición magmática hacia alteración potásica hidrotermal.

De esta manera, estas nuevas gráficas validan que los modelos profundos con interpretabilidad explícita superan la rigidez de los diagramas convencionales. Así, las contribuciones principales se sintetizan en un marco predictivo flexible y generalizable para evaluar secuencias volcánicas complejas sin requerir bases de datos masivas previamente etiquetadas, una innovación arquitectónica basada en el acoplamiento entre la representación latente no lineal y la estimación probabilística continua potenciada por la interpretabilidad y una optimización operativa que reduce drásticamente la incertidumbre en la interpretación multielemental para agilizar la toma de decisiones estratégicas en la exploración minera.

Como trabajo a futuro, a partir del marco metodológico (Autoencoders, Modelos de Mezcla Gaussiana (GMM) e interpretabilidad SHAP), los siguientes avances inmediatos se orientan hacia la escalabilidad espacial del modelo. Esto incluye la integración de coordenadas geográficas y modelos de elevación digital (DEM) directamente en la arquitectura de compresión latente para modelar la continuidad espacial de las zonas de alteración hidrotermal. Asimismo, se proyecta refinar la automatización documental para enlazar las salidas probabilísticas directamente con la generación dinámica de secciones y reportes técnicos bajo la normativa NI 43-101.

Como nuevas líneas de investigación, se plantea la implementación de Redes Neuronales Gráficas (GNN) para capturar de forma nativa las relaciones topológicas y la proximidad espacial entre muestras litogeoquímicas distribuidas irregularmente en un distrito minero. Otra línea relevante consiste en la fusión multimodal de datos, combinando las firmas geoquímicas de roca total con información de teledetección satelital e hiperespectral. Finalmente, resulta de gran interés extender el análisis de interpretabilidad mediante teoría de juegos hacia escenarios temporales, permitiendo evaluar la evolución geoquímica multietapa en complejos volcánicos activos y arcos magmáticos de larga duración.

Agradecimientos

Expresamos nuestro agradecimiento al ente gubernamental y laboratorio privado que autorizó el uso del dataset completo de 15 175 muestras y 38 elementos químicos de roca tomadas en diferentes campañas geológicas regionales para el desarrollo de esta investigación y propuesta pionera en la rama de geología de exploración minera y geología económica.

Conflicto de Interés

El dataset de datos litogeoquímicos utilizado en este estudio, la cual comprende un total de 15,175 muestras y la cuantificación de 38 elementos químicos, está sujeta a acuerdos de confidencialidad y derechos de propiedad con la entidad proveedora de los datos de exploración. Por consiguiente, el conjunto de datos completo no está disponible públicamente. Sin embargo, previa solicitud razonable y sujeto a la firma de un acuerdo de no divulgación (NDA), una versión anonimizada o un subconjunto representativo de los datos podría ser puesto a disposición por el autor de correspondencia, previa autorización del propietario del proyecto.

Disponibilidad de Datos y Código

Los datos y código que soportan los hallazgos del presente estudio están libremente disponibles en:

- Aplicación web
- GitHub
- Script Google Colab

Foto y Biografía de los Autores



Juan Francisco Quelal

Estudiante de 10mo semestre Ing. en Geología, UCE.

Experiencia en exploración greenfield, grassroots y brownfield de prospectos tipo pórfido Cu-Au y Cu-Mo, sistemas telescopados, epitermales LS y HS. Se desempeñó como geólogo junior en exploración near mine del distrito Los Ríos. Experiencia en modelamiento geológico 3D (Leapfrog Geo, Vulcan) y participante internacional en el curso de campo Michael J. Fitzgerald (SEG) en Nuevo México, EE.UU. Actualmente investiga la secuencia de vetillo en el Yacimiento Mirador e IA aplicada.



Rai Torres

Estudiante de 10mo semestre Ing. en Geología, UCE.

Interés en geotecnia, minería y petróleo. Prácticas en EP PETROECUADOR, Municipio de Alausí, ECU 911 y levantamiento de fenómenos de remoción en masa (Aluvión de La Gasca). Experiencia en microscopía, sedimentología, perforación geotécnica, registro de testigos y herramientas SIG (ArcGIS, QGIS), complementado con la aplicación de flujos de trabajo basados en Machine Learning para problemas geo-ambientales.



Alexis Cantares Morales

Estudiante de 10mo semestre Ing. en Geología, UCE.

Formación orientada a la geología aplicada, cartografía geológica y análisis geoespacial. Desempeño en Estudios de Impacto Ambiental como cartógrafo para proyectos de ingeniería. Experiencia en el procesamiento e interpretación de información geológica y geoespacial mediante herramientas SIG. Sus áreas de interés comprenden vulcanología, exploración minera e hidrocarbúfera y aplicación de inteligencia artificial en las geociencias.



Bryan Lascano

Estudiante de 10mo semestre Ing. en Geología, UCE.

Practicante en el Instituto de Investigación Geológica y Energética (IIGE) en separación de minerales pesados, y en la Comisión Ejecutora Río Coca (CERC – CELEC EP) en levantamientos geológicos y geotécnicos. Intereses centrados en investigación aplicada en geofísica, geología y geotecnia.



Aarón Garrido

Estudiante de 10mo semestre Ing. en Geología, UCE.

Formación en hidrocarburos y minería en empresas públicas. Experiencia en sedimentología, petrografía (microscopía óptica, DRX, MEB), registros eléctricos, evaluación de testigos y muestreo geológico. Manejo de AutoCAD, SIG, modelamiento geocientífico (Leapfrog Geo y Petrel) y herramientas de IA orientadas a la optimización de análisis geológico.



Christian Mejía

Profesor Titular, UCE.

Docente e investigador sobre Inteligencia Artificial en la Universidad Central del Ecuador. PhD en Informática por la Universidad de Alicante, España (2023). Experiencia en proyectos de Machine Learning y Deep Learning, especialmente en visión por computadora y procesamiento del lenguaje natural.



Jonathan Albuja

Ingeniero Geólogo – Presidente de Geoligans Consulting S.A.S.

Ingeniero Geólogo con 10 años de experiencia en exploración minera (pórfidos Cu, epitermales Au y sistemas magmático-hidrotermales). Ha trabajado con CODELCO (EMSAEC), Cornerstone, Titan Minerals, Hanrine, SYR Geociencias e IIGE. Co-descubridor del prospecto Estrellita y líder del descubrimiento de los pórfidos El Huato y Lumapamba Sur. Actualmente participa en el Proyecto Santa Bárbara (Auro Metals) y preside Geoligans Consulting S.A.S.

References

- Rick K. Valenta, Deanna Kemp, John R. Owen, Glen D. Corder, and Éléonore Lèbre. Re-thinking complex orebodies: Consequences for the future supply of critical minerals. *Journal of Cleaner Production*, 220:816–826, 2019.
- C. F. Blain. Determination of strategy in mineral exploration. *Mineralium Deposita*, 35(8):793–800, 2000.
- A. Joly, A. Porwal, and T. C. McCuaig. Exploration targeting for orogenic gold deposits in the yilgarn craton, western australia: A mineral systems approach. *Ore Geology Reviews*, 48:349–383, 2012.
- Jon M. A. Hronsky and David I. Groves. Science of targeting: Definition, strategies, targeting methodology and case histories. *Australian Journal of Earth Sciences*, 55(1):3–21, 2008.
- Jeff R. Harris and Eric C. Grunsky. Predictive lithological mapping of canada’s north using database compilation and machine learning. *Journal of Maps*, 11(1):169–176, 2015.
- D. Lord, M. Etheridge, M. Willson, F. Feldman, and G. Hall. Measuring exploration success: An analysis of decision making and performance in mineral exploration. *SEG Newsletter*, (45):1–16, 2001.
- Maurice A. Chaffee. Geochemical signatures of porphyry copper deposits in southwestern north america. In S. R. Titley, editor, *Advances in Geology of the Porphyry Copper Deposits*, pages 227–235. University of Arizona Press, 1982.
- Brendan A. McNulty and Gavin M. Jowitt. Barriers to and trends in mineral exploration performance. *Geology Today*, 35(6):222–228, 2019.
- Igor G. Gonçalves, Luís G. Eirado, and Rafael M. Souza. Lithogeochemical domain classification using gaussian mixture models in porphyry deposits. *Journal of Geochemical Exploration*, 234:106930, 2022.
- Eric C. Grunsky. The interpretation of geochemical survey data. *Geochemistry: Exploration, Environment, Analysis*, 10(1):27–74, 2010.
- Frits P. Agterberg. Geostatistics and mathematical geology: Past, present and future. *Mathematical Geosciences*, 46(7):775–788, 2014.
- Seyed Hassan Zangeneh et al. Geochemical anomaly detection and feature selection using variational autoencoders (vae) in porphyry copper exploration. *Computers & Geosciences*, 182:105490, 2024.
- Hugh R. Rollinson. *Using Geochemical Data: Evaluation, Presentation, Interpretation*. Longman Scientific & Technical, Harlow, 1993.
- Alfred Harker. The natural history of igneous rocks. *Macmillan*, 1909.
- T. N. Irvine and W. R. A. Baragar. A guide to the chemical classification of the common volcanic rocks. *Canadian Journal of Earth Sciences*, 8(5):523–548, 1971.
- Marc J. Defant and Mark S. Drummond. Derivation of some modern arc magmas by melting of young subducted lithosphere. *Nature*, 347(6294):662–665, 1990.
- Jeremy P. Richards. High sr/y magmas reflect arc maturity, contentedness, and prospective metallogeny. *Economic Geology*, 106(7):1075–1081, 2011.
- Renguang Zuo and Zhiyong Wang. Machine learning for mineral prospectivity mapping. *Earth-Science Reviews*, 207:103241, 2020.

- Yihui Xiong, Renguang Zuo, and E. John M. Carranza. Mapping multivariate geochemical anomalies associated with mineral deposits using autoencoders. *Computers & Geosciences*, 151:104761, 2021.
- Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 2017a.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- Robert R. Loucks. Distinctive geochemical signatures of barren versus porphyry copper-fertile magmas: Implications for outcomes of lower-crustal magmatic differentiation. *Geochimica et Cosmochimica Acta*, 146:273–297, 2014.
- S. Xie, Y. Chen, and K. Zhou. Advances in the processing of geochemical data for mineral exploration. *Computers & Geosciences*, 2021.
- Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, pages 4765–4774, 2017b.
- Canadian Securities Administrators. National instrument 43-101: Standards of disclosure for mineral projects. Regulation, Canadian Securities Administrators (CSA), 2011. URL <https://www.bscsc.bc.ca/securities-law/law-and-policy/national-instruments/43-101>.
- John Aitchison. *The Statistical Analysis of Compositional Data*. Chapman and Hall, London, 1986.
- Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Timothy S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, et al. TensorFlow: Large-scale machine learning on heterogeneous distributed systems, 2016.
- François Chollet et al. Keras. <https://keras.io>, 2015.
- Streamlit Inc. Streamlit: The fastest way to build and share data apps. <https://streamlit.io>, 2024.
- B Ronald Frost, Calvin G Barnes, William J Collins, Richard J Arculus, David J Ellis, and Carol D Frost. A geochemical classification for granitic rocks. *Journal of Petrology*, 42(11):2033–2048, 2001.
- Eric AK Middlemost. Naming materials from the magma kingdom. *Earth-Science Reviews*, 37(3-4):215–224, 1994.
- M Santosh and Soichi Omori. Fluid inclusion and stable isotope studies of ore-forming fluids in hydrothermal deposit systems. *Lithos*, 119(3-4):245–258, 2010.
- TH Green. Experimental studies of trace-element partitioning applicable to igneous petrogenesis—sedona 16 years later. *Chemical Geology*, 117(1-4):1–36, 1994.
- John A Winchester and PA Floyd. Geochemical discrimination of different magma series and their differentiation products using immobile elements. *Chemical Geology*, 20:325–343, 1977.
- JR Lang and SR Titley. Porphyry copper-gold-molybdenum deposits of northern chile. *Mineralium Deposita*, 36: 210–221, 2001.
- James M Brenan, HF Shaw, FJ Ryerson, and DL Phinney. Rutile-aqueous fluid partitioning of nb, ta, hf, zr, u and th: implications for subduction zone magmatism. *Earth and Planetary Science Letters*, 135(1-4):1–11, 1995.
- International Organization for Standardization and International Electrotechnical Commission. Requisitos generales para la competencia de los laboratorios de ensayo y calibración. Technical Report ISO/IEC 17025:2017, International Organization for Standardization, Geneva, Switzerland, 2017.
- Kim H Esbensen and Claas Wagner. Representative sampling, qa/qc and theory of sampling (tos)—fundamental prerequisites for reliable analytical results. *Trends in Analytical Chemistry*, 126:115860, 2020.
- Clemens Reimann, Peter Filzmoser, Robert Garrett, and Rudolf Dutter. *Statistical Data Analysis for Environmental Sciences and Engineering*. John Wiley & Sons, 2008.
- Marina Totland, Kym E Jarvis, and Ian Jarvis. Assessment of dissolution techniques for the analysis of geological samples by plasma spectrometry. *Chemical Geology*, 95(1-2):35–62, 1992.
- Gwendy EM Hall. Inductively coupled plasma mass spectrometry in geoanalysis. *Journal of Geochemical Exploration*, 44(1-3):201–240, 1992.
- Clifford R Stanley and David Lawie. Estimating sampling errors in geochemical surveys. *Geochemistry: Exploration, Environment, Analysis*, 7(1):73–82, 2007.
- Jean S Kane. Reference materials for chemical analysis of geological materials: history, current status, and future needs. *Geostandards and Geoanalytical Research*, 16(2):121–131, 1992.
- Clifford R Stanley and Alastair J Sinclair. A comparison of error estimation techniques in exploration geochemistry. *Journal of Geochemical Exploration*, 36(1-3):129–149, 1990.

- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- David R. Cooke, Pete Hollings, and John L. Walshe. Giant porphyry deposits: Characteristics, distribution, and tectonic controls. *Economic Geology*, 100(5):801–818, 2005.
- Wei-Dong Sun, Ru-Fang Huang, He Li, Yan-Bin Hu, Cong-Cong Zhang, Shi-Jiao Sun, Li-Peng Zhang, Xing Ding, Cong-Ying Li, Robert E. Zartman, and Ming-Xing Ling. Porphyry deposits and oxidized magmas. *Ore Geology Reviews*, 65:97–131, 2015. doi:10.1016/j.oregeorev.2014.09.004.