I CONVENCIÓN INTERNACIONAL FCI
Impacto de la inteligencia artificial en la ingeniería.

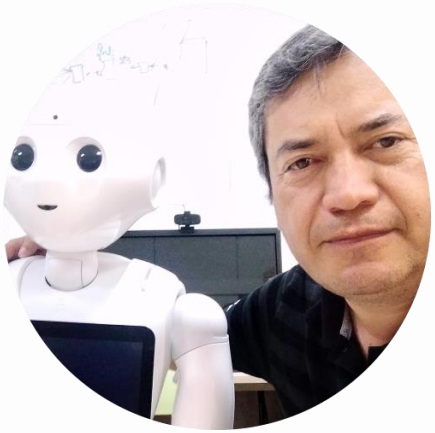

Dr. Christian Mejía-Escobar

Docente investigador en Computación, Inteligencia Artificial y Estadística (FIGEMPA-UCE).
PhD en Informática, Universidad de Alicante, España, 2023.
Máster en Ingeniería Eléctrica, opción Computación, CINVESTAV, México DF., 2007.
Ingeniero de Sistemas, EPN, Quito, Ecuador, 1999.
Tutor y revisor de tesis de pregrado y posgrado.
Autor y coautor de varias publicaciones indexadas.
Revisor para revistas internacionales.

Predicción de deslizamientos mediante Machine Learning y Deep Learning

Guerrero-Rodriguez, B., Garcia-Rodriguez, J., Salvador, J., Mejia-Escobar, C., Bonifaz, M., Gallardo, O. (2022). **Landslide Prediction with Machine Learning and Time Windows**. In Bio-inspired Systems and Applications: from Robotics to Ambient Intelligence. IWINAC 2022. Lecture Notes in Computer Science, vol 13259. Springer, Cham. https://doi.org/10.1007/978-3-031-06527-9_19

Guerrero-Rodriguez, B., Garcia-Rodriguez, J., Salvador, J., Mejia-Escobar, C., Bonifaz, M., Gallardo, O. (2022). **Defining High Risk Landslide Areas Using Machine Learning**. In: Bio-inspired Systems and Applications: from Robotics to Ambient Intelligence. IWINAC 2022. Lecture Notes in Computer Science, vol 13259. Springer, Cham. https://doi.org/10.1007/978-3-031-06527-9_18

Byron Guerrero-Rodriguez, Jose Garcia-Rodriguez, Jaime Salvador, Christian Mejia-Escobar, Shirley Cadena, Jairo Cepeda, Manuel Benavent-Lledo, and David Mulero-Perez. 2024. **Improving landslide prediction by computer vision and deep learning**. Integr. Comput.-Aided Eng. 31, 1 (2024), 77–94. https://doi.org/10.3233/ICA-230717

CONTENIDO

- ❑ Problemática
- ❑ Objetivo de estudio
- ❑ Metodología de la investigación
- ❑ Discusión y resultados
- ❑ Conclusiones

Deslizamientos de tierra

- Fenómeno frecuente a nivel local y mundial
- Masa de tierra, rocas o material que se desplaza cuesta abajo por una pendiente
- Pueden ser eventos muy **destructivos**
- Predicción es crucial, pero **compleja**
- Métodos convencionales:
  - Fórmulas o reglas predefinidas
  - Variables limitadas
  - Tratamiento estático
  - Expertos especialistas
  - Enfoque determinista

Figura 1: Afectación a personas y daños a infraestructura por deslizamientos

OBJETIVO DE ESTUDIO

Objetivo general:

Emplear algoritmos de machine learning (ML) clásicos y deep learning (DL) para la predicción de deslizamientos.

Objetivos específicos:

1) Elaborar un **conjunto fiable de datos cuantitativos e imágenes** de los deslizamientos de la zona de estudio.
2) Analizar la **precipitación dinámicamente** en ventanas de tiempo (3, 5, 7, 10, 15, 20, 30 días).
3) Generar **mapas de susceptibilidad** e identificar **sitios** de mayor riesgo.

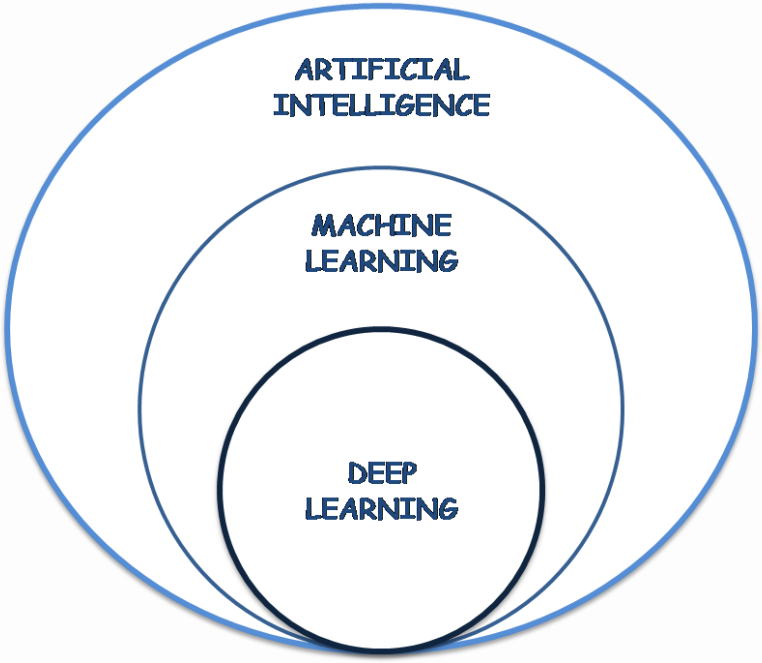

Figura 2: Relación entre IA, ML y DL.

METODOLOGÍA DE LA INVESTIGACIÓN

- Aprendizaje a partir de la experiencia (**historial eventos**)
- Selección de **variables influyentes**
- ML y DL **supervisados**: aprender relación ocurrencia-variables
- Entrenamiento: clasificación binaria (ocurrencia y ausencia)
- Predicción: regresión (probabilidad ocurrencia)
- Herramientas: QGIS, SagaGIS, ArcGIS, R, Python, Google Earth, Google Colaboratory
- La metodología puede ser generalizada

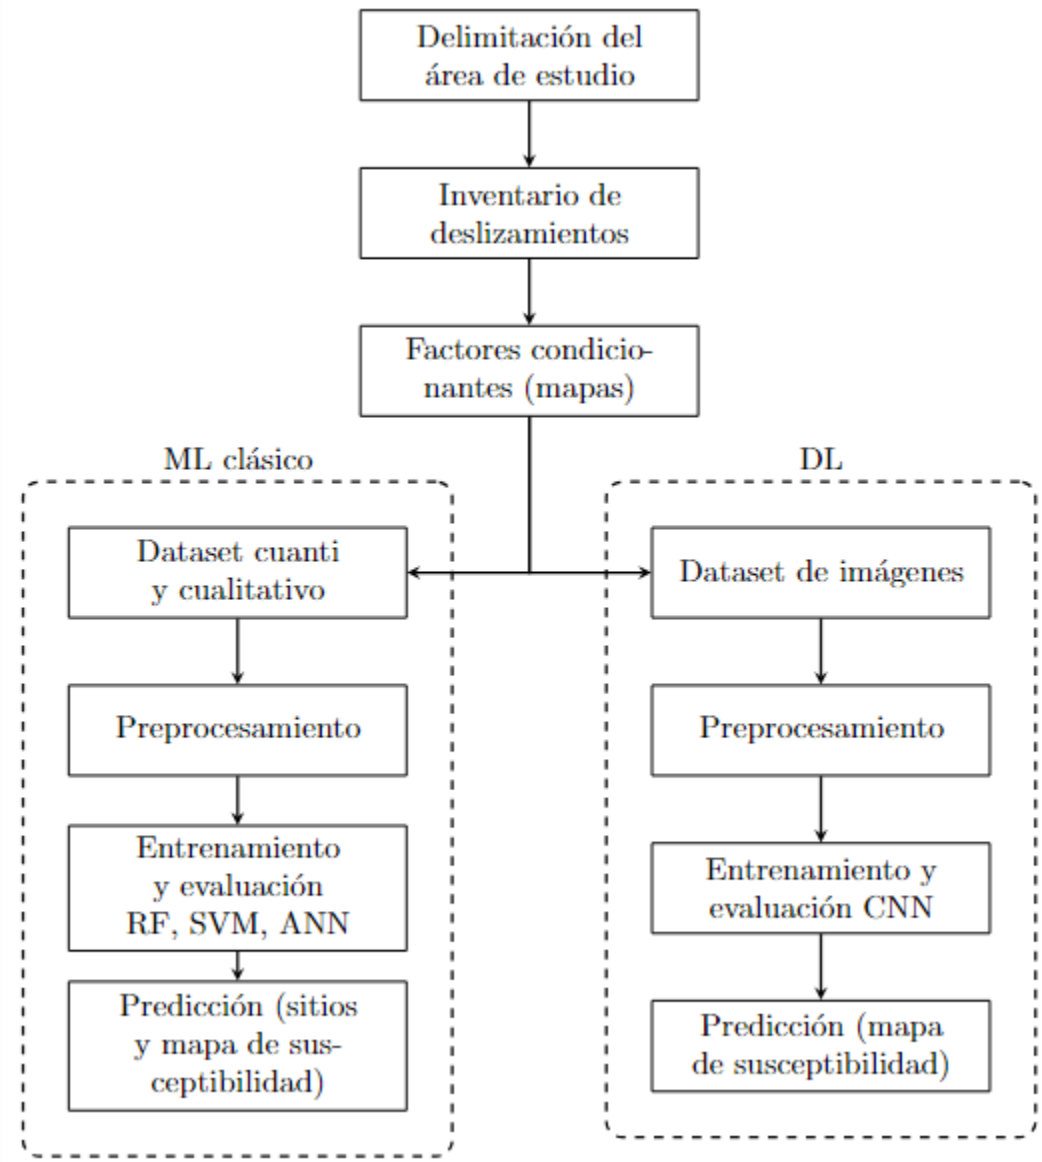

Figura 3: Flujograma de trabajo para la predicción de deslizamientos usando ML y DL.

Delimitación del área de estudio

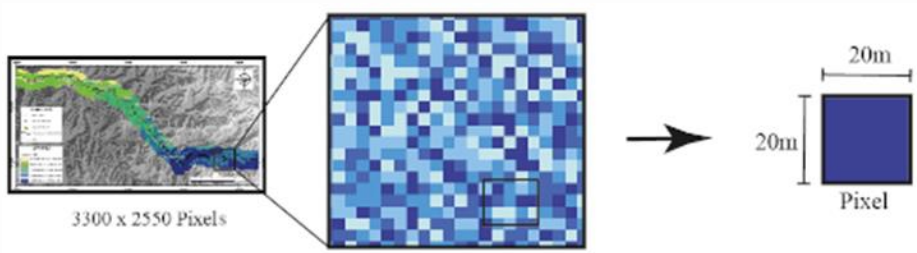

- Vía estratégica que une Sierra y Costa (~100 km)
- Margen de influencia (264.92 km^2)
- Cuadrícula de celdas (píxeles): **unidad básica**
- Tamaño conveniente: 20 m x 20 m

Inventario de deslizamientos

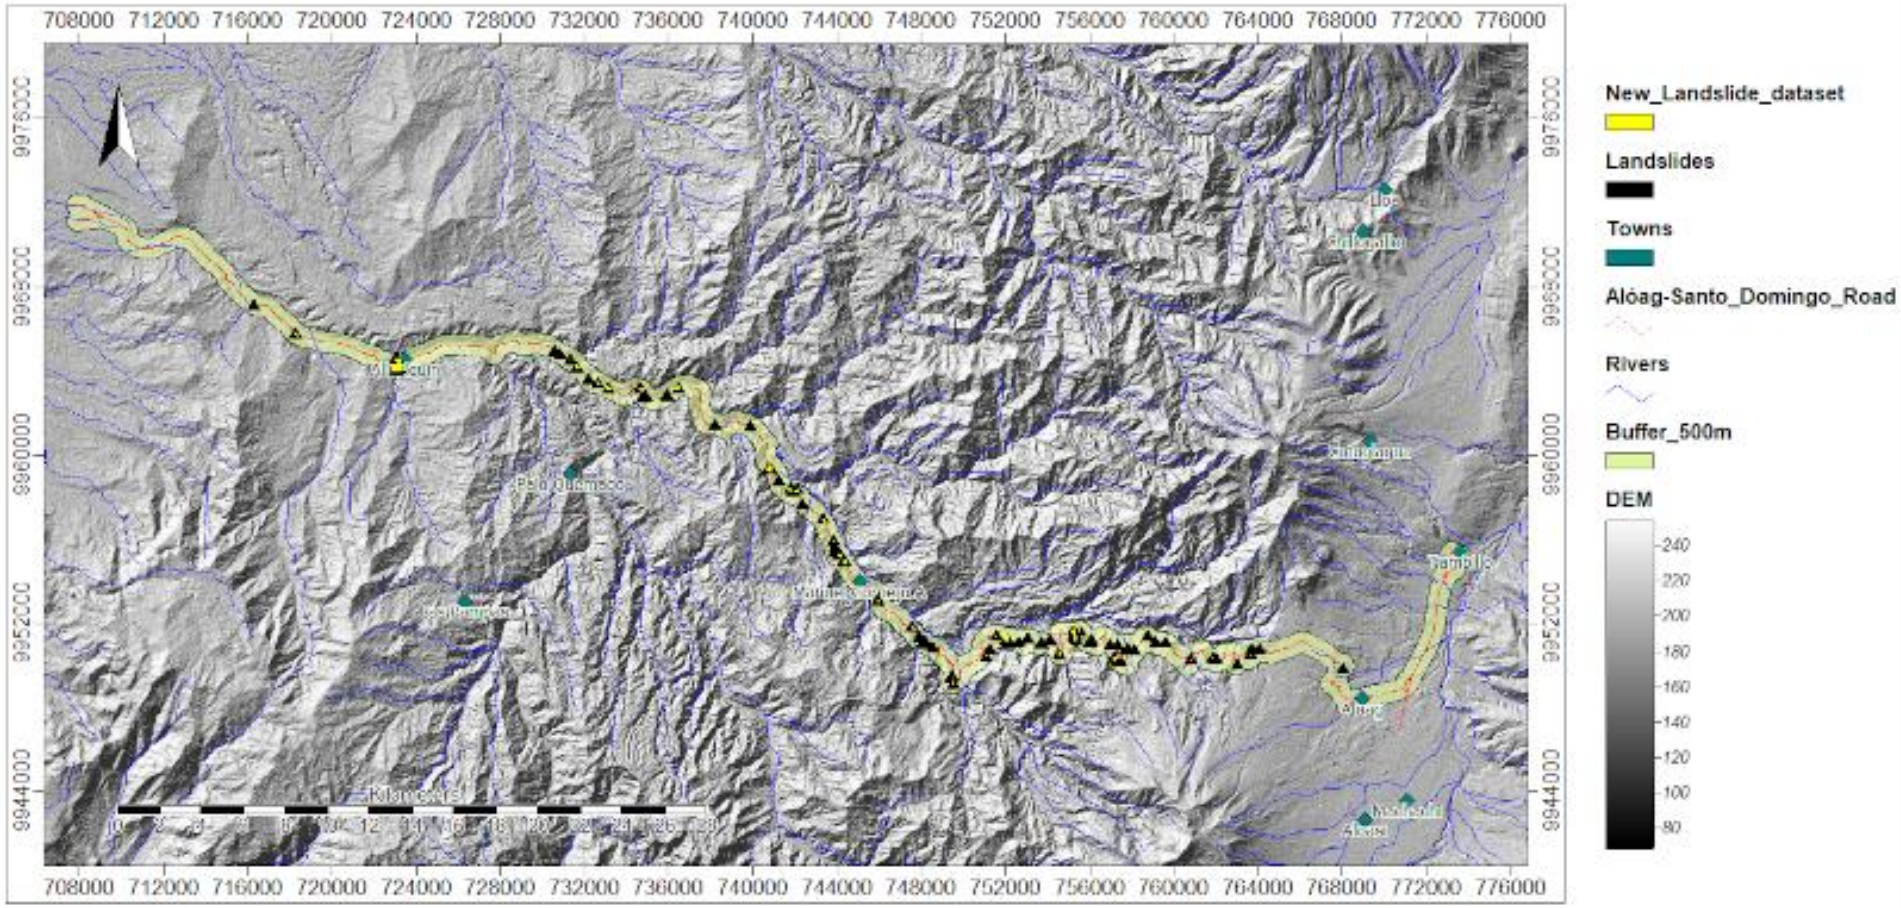

- La localización de deslizamientos en el área es fundamental para la predicción
- *"Lo que sucedió en el pasado puede indicar lo que ocurrirá en el futuro"*
- Fuente: GAD Pichincha: 45 eventos registrados (2014)
- Actualizado a 2021 (noticias, videos y redes sociales): total de **75 eventos**

Dataset ML clásico

Tabla 1: Estructura y propiedades de las variables consideradas para la predicción de deslizamientos.

Name	Class	Unit of measure	Type	Field
Landslide	Binary	-	Target	Risk management
Elevation	Quantitative	Meters (m)	Predictor	Geomomorphology
Slope	Quantitative	Grades (º)	Predictor	Geomomorphology
Aspect	Quantitative	Grades (º)	Predictor	Geomomorphology
Profile curvature	Quantitative	Adimensional	Predictor	Geomomorphology
Plane curvature	Quantitative	Adimensional	Predictor	Geomomorphology
Vegetation	Qualitative	-	Predictor	Land use
Lithology	Qualitative	-	Predictor	Geology
Max. Temp.	Quantitative	Grades (℃)	Predictor	Meteorology
Min. Temp.	Quantitative	Grades (℃)	Predictor	Meteorology
Wind speed	Quantitative	m/s	Predictor	Meteorology
Solar radiation	Quantitative	W/m^2	Predictor	Meteorology
Relative humidity	Quantitative	mmH2O	Predictor	Meteorology
3-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology
5-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology
7-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology
10-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology
15-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology
20-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology
30-day cum. precip.	Quantitative	mmH2O	Predictor	Meteorology

Preprocesamiento del dataset ML clásico

1) **Transformación de variables cualitativas a cuantitativas**
   - Litología (4 clases) y vegetación (3 clases)
   - Técnica "**One-hot** encoding"

2) **Balance de datos**
   - Casos positivos: **1407** de 662303 registros
   - Casos negativos: escasa o nula pendiente, litología y vegetación desfavorables

3) **Normalización**
   - Las variables fluctúan en diferentes escalas de valores
   - Las unidades de medida son diversas
   - Estandarización automática entre **0 y 1**

4) **División del conjunto de datos**
   - Subconjunto de **entrenamiento** (80%): aprendizaje y ajuste de parámetros
   - Subconjunto de **prueba** (20%): evaluar el rendimiento del modelo

Entrenamiento y evaluación ML clásico


```
ANN_model = neuralnet(V18~V1+V2+V3+V4+V5+V6+V7+V8+V9+V10+V17+
                NL1+NL2+NL3+NL4+NV1+NV2+NV3,
                data = training_set, hidden = 4, act.fct = 'tanh')

RF_model = randomForest(V18~V1+V2+V3+V4+V5+V6+V7+V8+V9+V10+V17+
                NL1+NL2+NL3+NL4+NV1+NV2+NV3,
                data = training_set, importance = TRUE,
                ntree = 1000, mtry = 4, maxnodes = 7)

SVM_model = svm(V18~V1+V2+V3+V4+V5+V6+V7+V8+V9+V10+V17+
                NL1+NL2+NL3+NL4+NV1+NV2+NV3,
                data = training_set, kernel = 'sigmoid',
                cost = 10, cross = 2, scale = false)
```

Tabla 2: Precisión de los modelos para cada precipitación acumulada con los datos de prueba.

Cumulative precipitation	ANN accuracy (%)	RF accuracy (%)	SVM accuracy (%)
3-day	99.47	98.31	90.54
5-day	99.47	97.56	90.81
7-day	98.75	97.03	90.90
10-day	99.11	98.18	91.07
15-day	99.29	97.56	91.07
20-day	99.64	99.25	91.07
30-day	99.47	98.00	91.16

Predicción (mapa de susceptibilidad)

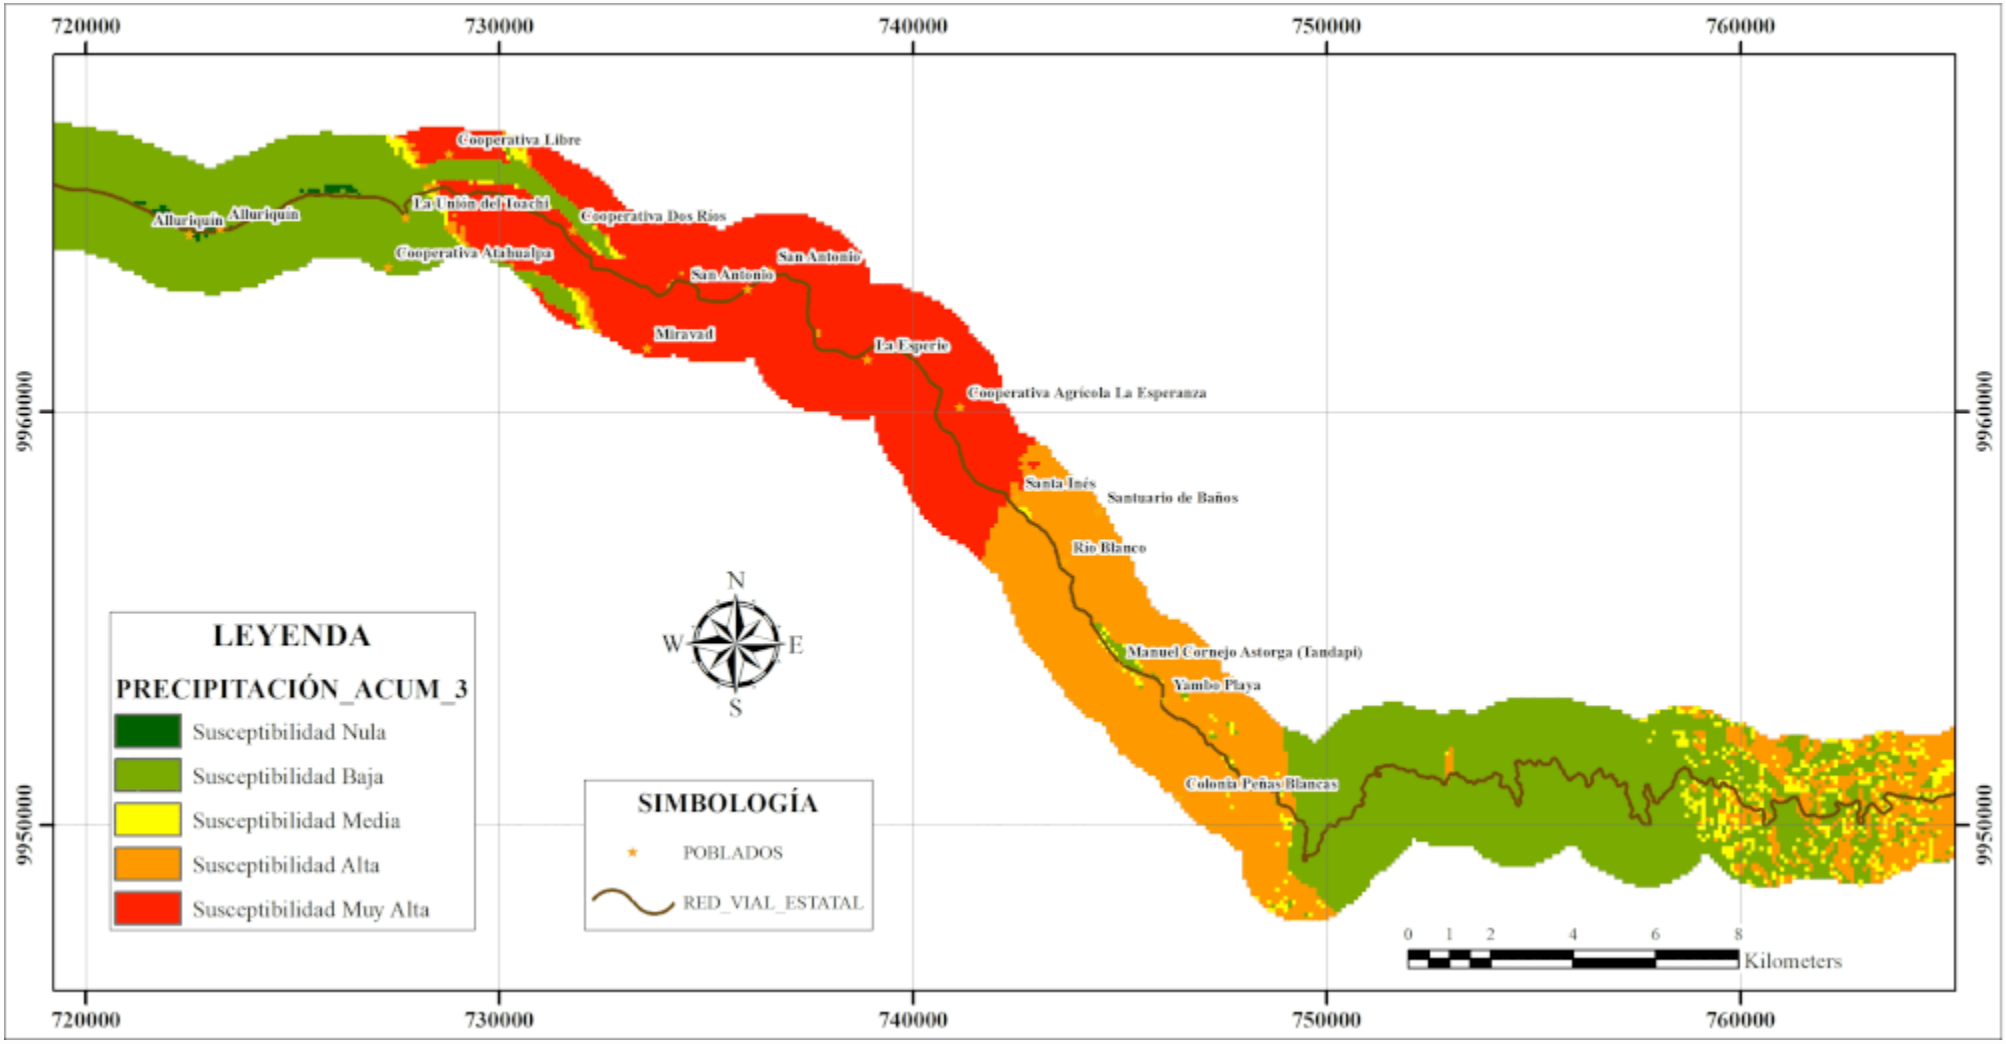

GIF animado de transición de los 7 mapas muestra que el mayor riesgo de deslizamientos va del **S-E** al **N-O** a medida que aumentan los días de lluvia.

Predicción (sitios de mayor riesgo)
ML clásico

Tabla 3: Localización de los tramos de mayor riesgo para cada precipitación acumulada.

Cumulative precipitation	Risk of landslide	Location-from		km	Location-to		km
3-day	Very high	-0.37961	-78.82371	55	-0.31440	-78.94120	70
	High	-0.44860	-78.56141	41	-0.41954	-78.79244	46
5-day	Very high	-0.37961	-78.82371	55	-0.33892	-78.86701	60
	High	-0.44189	-78.67033	20	-0.37961	-78.82371	55
7-day	Very high	-0.26453	-79.11131	95	-0.257380	-79.12530	97
	High	-0.37687	-78,83014	48	-0.26453	-79.11131	95
10-day	Very high	-0.27634	-79.07719	89	-0.25738	-79.12530	97
	High	-0.38187	-78.82223	45	-0.27634	-79.07719	89
15-day	Very high	-0.31599	-78.95359	73	-0.27634	-79.07719	89
	High	-0.32689	-79.65159	82	-0.27634	-79.16709	93
20-day	Very high	-0.31440	-78.94120	70	-0.27634	-79.07719	89
	High	-0.32409	-78.91820	67	-0.27634	-79.07719	89
30-day	Very high	-0.33309	-78.89530	65	-0.31433	-78.93438	69
	High	-0.44189	-78.67033	20	-0.27634	-79.07719	89

Dataset de imágenes DL (CNN)

- Tabla cuantitativa: costosa en **tiempo y esfuerzo**
- Uso directo de imágenes
- **Localización del origen** del deslizamiento (corona)
- Imágenes más grandes incorporan información innecesaria
- Imagen de entrada: 19 canales, uno por variable
- Total: 262 imágenes
  - 50% ocurrencia
  - 50% ausencia deslizamiento

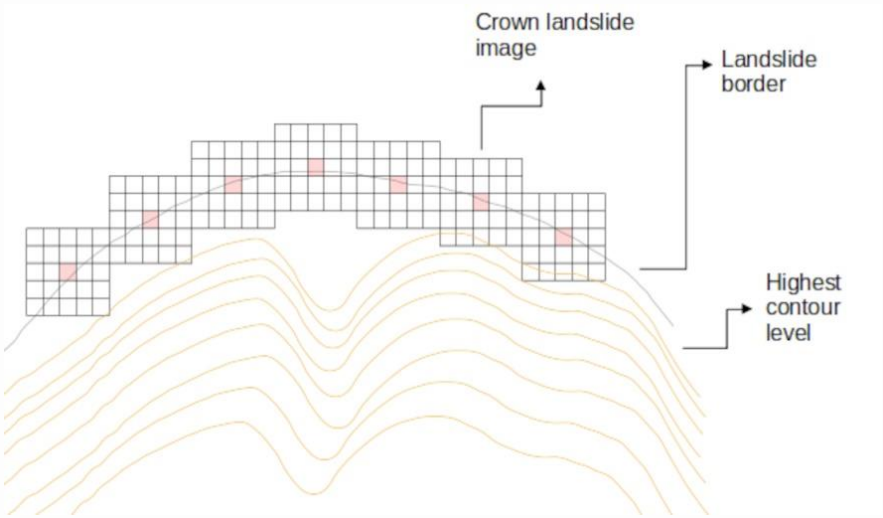

Figura 4: Corona representada con imágenes 5x5 px.

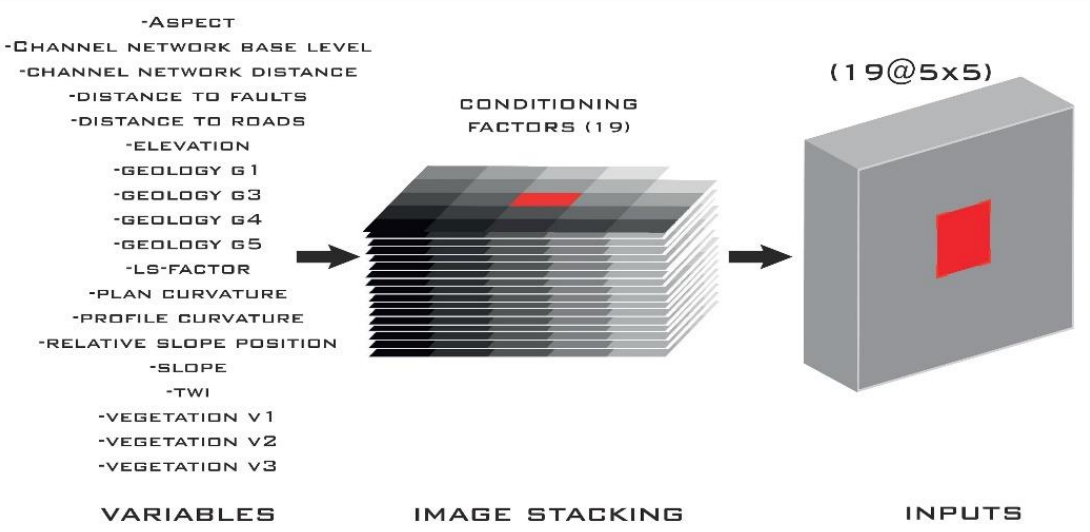

Figura 5: Apilamiento de variables como canales de una imagen.

Entrenamiento y evaluación DL (CNN)

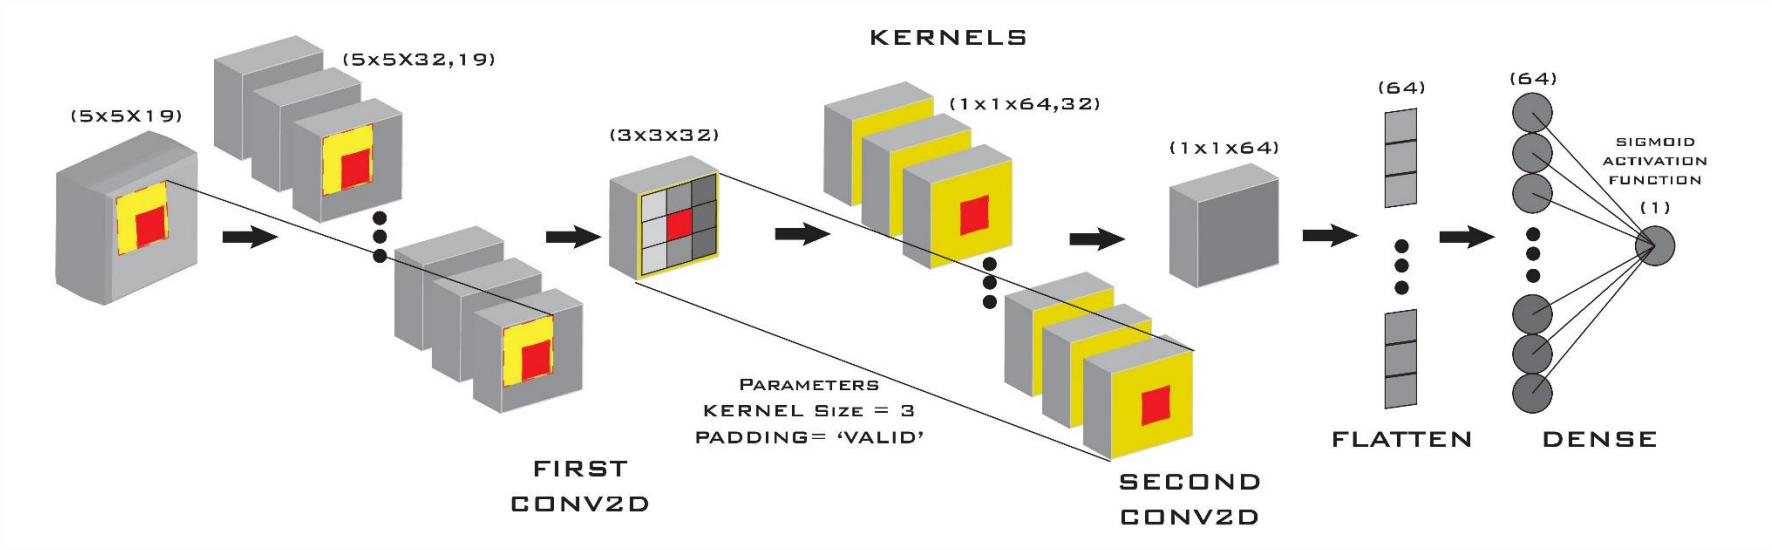

Figura 6: Arquitectura de la red neuronal convolucional personalizada para la predicción de deslizamientos.

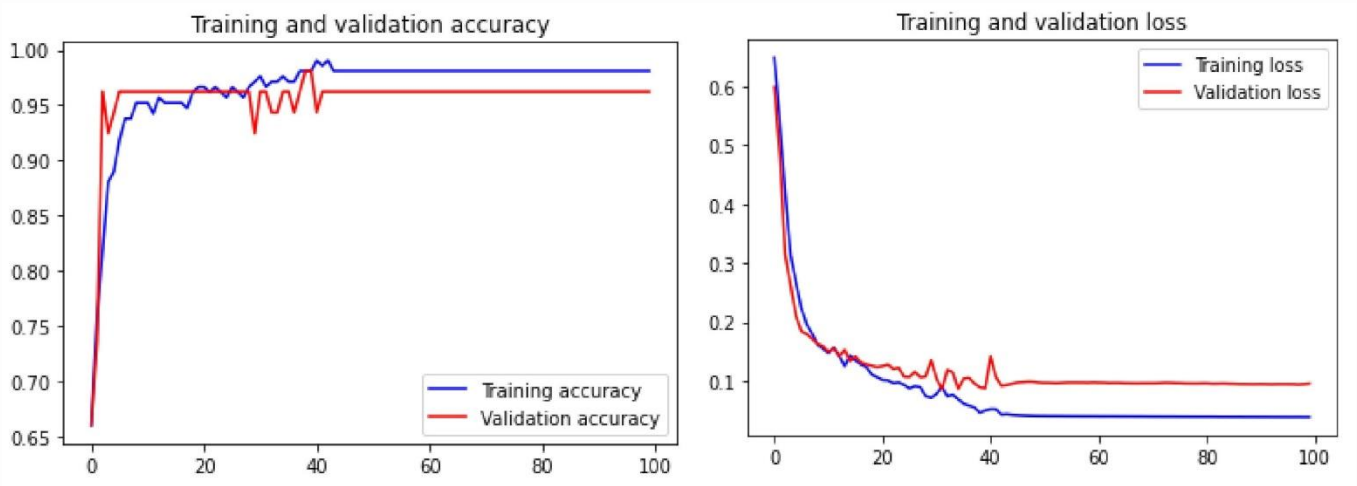

Figura 7: Curvas de aprendizaje de precisión y pérdida.

Predicción (mapa de susceptibilidad) DL (CNN)

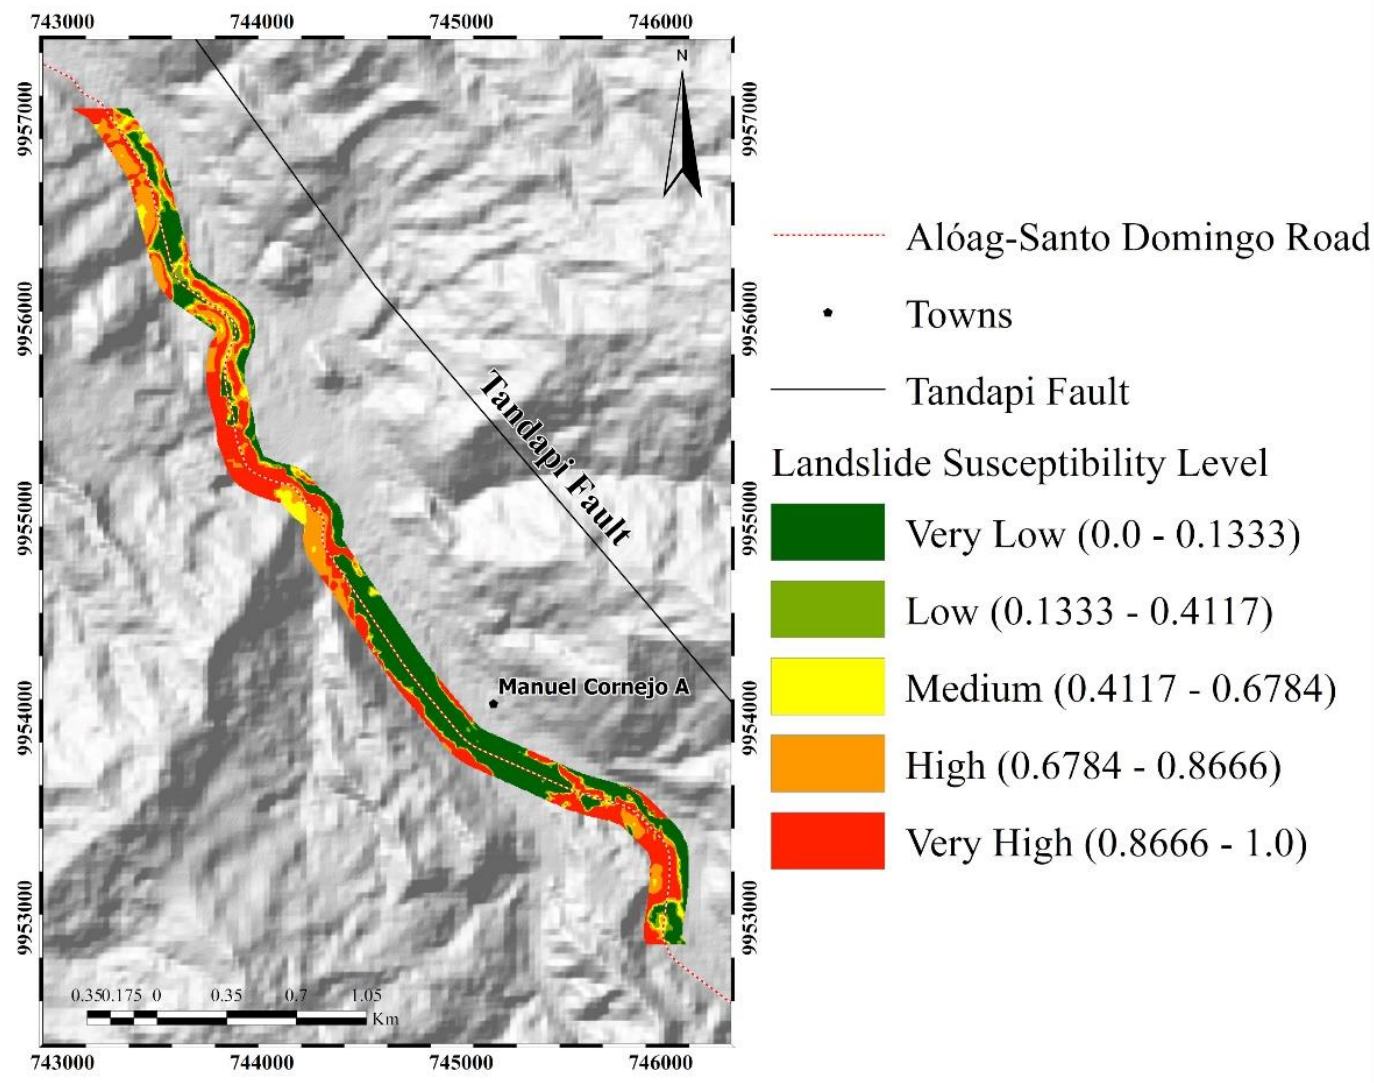

CONCLUSIONES

- Los resultados experimentales utilizando algoritmos de ML clásico (**ANN**, RF y SVM) y DL (CNN) indican la **conveniencia y efectividad** de estos métodos para la predicción de deslizamientos.
- El manejo dinámico de la precipitación en diferentes ventanas de tiempo sugiere una fuerte correlación del fenómeno con la acumulación de lluvia, lo que permite una **predicción multitemporal** de deslizamientos.
- Los modelos obtenidos (ML y DL) son útiles para generar **mapas de susceptibilidad** e identificar tramos de la vía de más alto riesgo. Mientras se incrementan los días de precipitación, el mayor riesgo va de S-E a N-O.
- Primer trabajo usando ML y DL en la vía, puede soportar la **toma de decisiones** para implementar compactación del terreno, mallas de protección, puestos de auxilio o medidas preventivas en los tramos más susceptibles.

Predicción de deslizamientos mediante Machine Learning y Deep Learning

Christian Mejía-Escobar, PhD.

Email: cimejia@uce.edu.ec / Web: cimejia.github.io

I CONVENCIÓN INTERNACIONAL FCI
Impacto de la inteligencia artificial en la ingeniería.